端到端任务型对话系统的
多领域扩展与半监督学习研究

（申请清华大学工学硕士学位论文）

培 养 单 位 ： 电子工程系

学　　科 ： 信息与通信工程

研　究　生 ： 张 亦 弛

指 导 教 师 ： 欧 智 坚　副研究员

二〇二〇年五月

Towards Multi-Domain and Semi-Supervised End-to-End Task-Oriented Dialogue Systems

Thesis Submitted to

Tsinghua University

in partial fulfillment of the requirement

for the degree of

Master of Science

in

Information and Communication Engineering

by

Yichi Zhang

Thesis Supervisor: Associate Professor Zhijian Ou

May, 2020

关于学位论文使用授权的说明

本人完全了解清华大学有关保留、使用学位论文的规定，即：

清华大学拥有在著作权法规定范围内学位论文的使用权，其中包括：（1）已获学位的研究生必须按学校规定提交学位论文，学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文；（2）为教学和科研目的，学校可以将公开的学位论文作为资料在图书馆、资料室等场所供校内师生阅读，或在校园网上供校内师生浏览部分内容。

本人保证遵守上述规定。

（保密的论文在解密后应遵守此规定）

作者签名：张亦弛　　导师签名：欧智坚

日　　期：2020年5月15日　　日　　期：2020年5月15日

摘　要

近年来，随着深度学习的发展，使用神经网络模型直接建模从用户输入到系统输出的端到端（End-to-End）系统，已逐渐取代了之前独立设计、分别训练各个功能模块的模块化系统，展现出良好的性能。在现有的端到端任务型对话系统模型中，有一类模型使用统一的序列到序列学习框架（Sequicity），依次解码对话状态等系统中间状态和最后的回复语句，在取得最佳任务型对话建模能力的同时，具有良好的可解释性，受到了研究界的广泛关注。

在本论文中，我们针对现有基于 Sequicity 框架的端到端对话模型存在的两个问题，进行了研究与改进。

第一，现有模型不支持包含多个领域的复杂场景下的任务型对话建模，无法解决包含领域转换的复杂任务。我们提出了一种新的模型结构，领域自适应的多级解码器网络 DAMD，可以自动判定当前对话的领域并对多领域对话状态进行追踪，解决了领域转换的难题。此外，针对多领域任务型对话中经常出现同一语境可对应不同系统回复的“一对多”问题，我们提出了一种多动作数据增强方法 MADA，结合 DAMD 给出了多元化对话策略学习的解决方案。

第二，现有模型在训练时，必须使用标注了对话状态等系统中间状态的有标注对话数据，标注开销很高。针对这个问题，我们首先对 Sequicity 框架进行了概率建模分析，指出概率建模上的局限性是造成上述问题的根本原因。然后，我们提出了一种新的基于状态空间模型的对话模型框架，并在新框架下提出了离散状态端到端对话模型 DSNet，可以利用无标注数据进行半监督学习，缓解了对标注数据的依赖。

本论文的创新点包括：

1. 提出领域自适应的多级解码器网络 DAMD，解决多轮对话建模问题。

2. 提出多动作数据增强方法 MADA，解决任务型对话中的“一对多”问题。

3. 提出基于状态空间模型的对话模型框架，解决现有框架理论上无法进行无监督学习的问题。

4. 提出离散状态端到端对话模型 DSNet 及其半监督学习方法，解决模型训练时过度依赖标注数据的问题。

关键词： 任务型对话系统；多领域；端到端对话建模；序列到序列学习；状态空间模型；半监督学习

Abstract

In recent years, with the development of deep learning, neural networks have shown promising performance on building end-to-end dialogue systems, which outperform the traditional modular systems that separately design and train each functional module. Among the existing end-to-end task-oriented dialogue systems, there is a type of model that uses a unified sequence-to-sequence learning framework (Sequicity) to model task-oriented dialogues. Given its state-of-the-art response generation results and good interpretability, models under the Sequicity framework have received extensive attention from the research community.

In this paper, we aim at improving end-to-end dialogue modeling. Specifically, we address two problems existing in the Sequicity framework, which greatly limit its applications.

First, existing models under the Sequicity framework cannot handle multi-domain task-oriented dialogues, especially those complex tasks with domain conversion. To address this problem, we propose the Domain-Aware Multi-Decoder network (DAMD), which can automatically determine the dialogue domain and track the multi-domain dialogue state. In addition, we propose a Multi-Action Data Augmentation (MADA) framework to address the common ”one-to-many” problem in multi-domain task-oriented dialogues, where the same context can lead to many different system responses.

Secondly, training existing models rely on fully annotated dialogue data, where the labeling cost is very high. To address this problem, we first show why models under the Sequicity framework cannot benefit from unlabeled data from the perspective of probabilistic modeling. Then we propose a new framework for task-oriented dialogue modeling based on the state-space model, and propose the Discrete State Network (DSNet) model under the new framework. We show DSNet can benefit from both labeled and unlabeled data under semi-supervised learning settings, which alleviates the dependency of labeled data.

Key Words: Task-oriented dialogue system; multi-domain; end-to-end dialogue modeling; sequence-to-sequence learning; state-space model; semi-supervised learning

目 录

第 1 章 引言 1
1.1 人机对话及任务型对话系统概述 1
1.2 研究问题与论文陈述 3
1.2.1 不支持多领域复杂对话建模 3
1.2.2 依赖标注数据进行训练 4
1.3 论文组织结构 5
第 2 章 研究背景和相关工作 6
2.1 任务型对话系统 6
2.1.1 对话领域知识本体 6
2.1.2 自然语言理解 7
2.1.3 对话状态跟踪 8
2.1.4 对话策略选择 9
2.1.5 自然语言生成 9
2.2 端到端对话建模 10
2.2.1 循环神经网络 10
2.2.2 序列到序列学习 12
2.2.3 基于多级编解码器的端到端对话模型 15
第 3 章 多领域任务型对话建模 18
3.1 领域自适应的多级解码网络模型 18
3.2 模型性能评估 21
3.2.1 数据集与评价指标 21
3.2.2 实现细节与基线模型介绍 22
3.2.3 实验结果与分析 23
3.3 基于 DAMD 模型的多元化策略学习 24
3.3.1 任务型对话中的一对多问题 25
3.3.2 多动作数据增强方法 26
3.3.3 实验结果与分析 29
第 4 章 基于状态空间模型框架的离散状态对话模型 31
4.1 基于 Sequicity 框架的端到端对话模型的概率建模分析 31
4.2 基于状态空间模型的对话模型框架 33

4.3 离散状态端到端对话模型 DSNet 35
4.3.1 模型整体结构 35
4.3.2 对话状态与系统对话动作的建模方式 38
4.4 DSNet 的无监督学习算法 40
4.4.1 序列模型的 SCVAE 算法 41
4.4.2 序列模型的 SCRWS 算法 42
4.5 实验结果 43
4.5.1 Camrest676 数据集 43
4.5.2 有监督实验结果与分析 44
4.5.3 半监督实验结果与分析 45
第 5 章 结论与展望 48
5.1 论文贡献总结 48
5.2 未来研究方向 48
插图索引 50
表格索引 51
参考文献 52
致 谢 59
声 明 60
附录 A SCRWS 中的 SMC 算法流程 61
个人简历、在学期间发表的学术论文与研究成果 62

主要符号对照表

NLU	自然语言理解（Natural Language Understanding）
DST	对话状态跟踪（Dialogue State Tracking）
DB	数据库（Database）
DPS	对话策略选择（Dialogue Policy Selection）
NLG	自然语言生成（Natural Language Generation）
Seq2Seq	序列到序列学习（Sequence-to-Sequence）
RNN	循环神经网络（Recurrent Neural Network）
$\boldsymbol{U}_t$	第 t 轮对话的用户输入
$\boldsymbol{C}_t$	第 t 轮对话的输入上下文，包括 $\boldsymbol{R}_{t-1}$ 和 $\boldsymbol{U}_t$
$\boldsymbol{B}_t$	第 t 轮对话的对话状态
$\boldsymbol{A}_t$	第 t 轮对话的系统对话动作
$\boldsymbol{A}_t^U$	第 t 轮对话的用户对话动作
$\boldsymbol{R}_t$	第 t 轮对话的系统回复语句
$\boldsymbol{DB}_t$	第 t 轮对话的数据库查询结果
h^{enc}	编码器隐状态
h^{dec}	解码器隐状态

第 1 章　引言

1.1　人机对话及任务型对话系统概述

开发具有像人一样交谈能力的对话机器人，或称对话系统（Dialogue System），可以说是人工智能中最困难的挑战之一。为了与人类进行自然而有意义的对话，对话系统需要具备理解自然语言，选择对话策略，并给出恰当自然语言表达的能力。经过数十年的研究和开发，对话系统已经取得了巨大的发展，并已从研究项目转变为每天有数亿人不断使用的商业系统。例如，国内外各大互联网公司开发的语音助手，如华为小 E，小米小爱同学，阿里小蜜，苹果 Siri，亚马逊 Alexa，谷歌 Home，微软小冰等等，已经让使用人机对话的方式进行天气查询、搜索、音乐播放、导航、导购、聊天等各种日常交互成为可能，正在逐渐改变人们的人机交互习惯，发挥着越来越重要的作用。

根据对话性质的不同，对话系统可以分为闲聊型（Chit-chat）、问答型（Question Answering）和任务型（Task-oriented）三类。在闲聊型对话系统[1-4] 中，系统的目标是帮助用户获得尽可能好的聊天体验，尽可能长时间地保持用户对于聊天的兴趣和注意力，例如微软小冰聊天机器人[5]。闲聊型对话的特点是对话内容无领域限制，用户在对话时不存在明确的目的。相比之下，在问答型对话系统[6-8] 和任务型对话系统[9-12] 中，用户的对话带有明确目的，系统需要借助特定领域的领域知识，帮助用户解决特定问题。如何与结构化知识数据库进行交互，并将数据库中查询到的信息通过自然语言呈现给用户，是这类系统需要考虑的一个重点问题。这两类系统的区别在于，问答系统采用一问一答的形式，不考虑对话历史信息，只能被动回答用户的问题，不会进行主动发问。而在任务型对话系统中，系统需要与用户进行多轮交互，以完成更为复杂的用户需求。为了更好地完成任务，系统需要记录、维护对话进行的状态，在用户提供的信息不足以完成任务时进行主动询问，以及选择能最快完成任务的对话策略等等，即具备针对复杂任务进行多轮对话规划的能力。图1.1给出了一个餐厅信息查询任务的人机对话示例，通过和用户的两轮交互，系统得到反映用户需求的对话状态“餐厅种类 = 快餐，价格 = 便宜”，成功在数据库中找到了符合要求的餐厅，并回应了用户对于该餐厅的进一步询问请求。本论文的研究工作围绕这种任务型对话系统进行。

传统的任务型对话系统使用一套模块化流水线式的框架[13] 解决多轮对话规划问题。如图1.2(a)所示，用户输入（语音或文本）首先被送入自然语言理解模块（Natural Language Understanding，NLU）中进行意图和语义解析，然后在对话状态

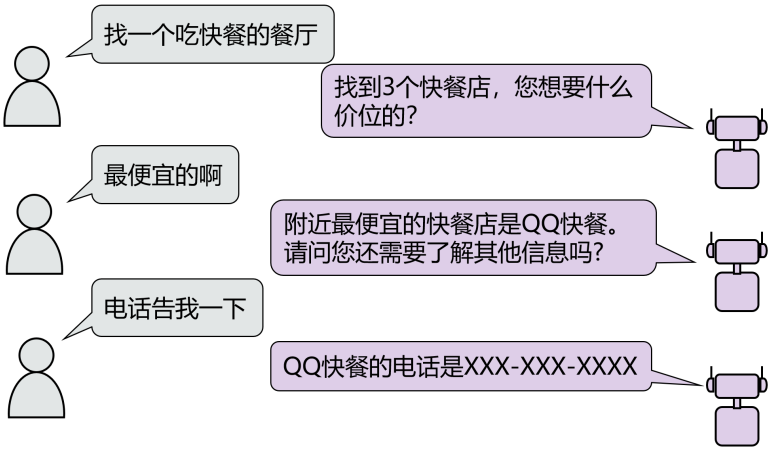

图 1.1　任务型对话示例：餐厅信息查询

跟踪（Dialogue State Tracking，DST）模块中与历史对话状态结合，之后与数据库交互并在对话策略选择模块（Dialogue Policy Selection）中选择系统应该采取的对话动作，最后在自然语言生成模块中（Natural Language Generation，NLG）生成对用户的回复语句。近年来，随着深度学习[14] 的迅猛发展，使用数据驱动的神经网络模型进行自然语言理解[15-16]、对话状态跟踪[17-18]、对话策略学习[19-20] 以及自然语言生成[21-22]，其性能已经逐渐超越了基于人为设计特征、规则和模板的传统方法，并且具有人工工作量少、模型泛化能力强等优势。然而，在系统搭建时，由于模块化系统的各个模块之间采用独立的网络模型，需要分别设计结构、准备数据、调整超参数、进行训练，模型设计和训练调试的时间成本很高。另一方面，由于不同研究者对采用的模块输入输出可能存在差异，搭建完整对话系统时会出现各模块之间输入输出的不适配问题，需要重新对各个模块的接口做出规定。这些问题极大限制了神经网络模型在模块化对话系统中的应用。

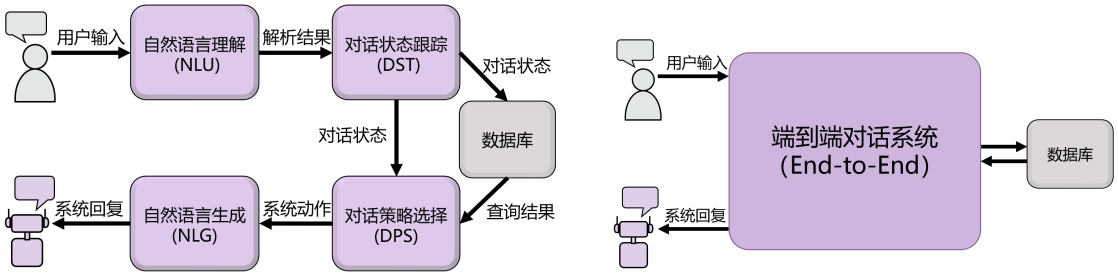

(a) 模块化系统　　(b) 端到端系统

图 1.2　任务型对话系统的两种系统框架

针对模块化系统的问题，研究者提出了端到端（End-to-End）系统框架，直接使用一个模型建模用户输入到系统回复输出的映射关系（图1.2(b)）。端到端系统

在训练时，对输入端到输出端之间所有的中间组件进行联合优化，因此只需要训练一次就可以得到完整的对话系统模型。早期的端到端对话系统，沿用了模块化系统中各个模块的网络结构设计，将各个模块连接到一起进行端到端训练，得到了超越模块化系统的性能[11,23-24]。随着基于编解码器神经网络（Encoder-Decoder Neural Network）的模型在神经翻译领域取得了性能上的重大突破[25-28]，这种可以直接进行序列到序列（Sequence-to-Sequence，Seq2Seq）学习的模型为端到端对话系统设计提供了一种新思路，即首先使用编码器网络将对话历史编码为向量表示，再使用解码器网络解码出自然语言回复语句，通过最大化生成回复在对话数据集上的似然对编解码器进行联合训练。虽然序列到序列学习在闲聊型对话建模中取得了不错的效果[1,29-30]，在应用于任务型对话系统时存在两个难点。第一，向量形式的隐状态无法直接和结构化数据库进行交互，需要借助规则[31] 或实体标注模型[32] 进行语义解析和对话状态跟踪，得到离散表示的对话状态①后，再去数据库中进行查询，端到端系统的整体性能受制于对话状态跟踪方法的性能。第二，由于在端到端系统内没有人可以观测、可以理解的中间状态，系统设计者难以诊断系统出错的原因。假如最后生成的回复不尽如人意，可能是系统对用户的语言理解有误、对话状态没有正确跟踪，也可能是选择了错误的对话策略，亦或是最终生成自然语言的质量不高。

近期，有研究者提出基于多级编解码器网络的 Sequicity 框架[33]，将对话状态定义为用户提到的关键信息词序列，使用两个解码器，先解码对话状态，再根据对话状态解码结果解码系统回复。Sequicity 这种使用端到端系统的隐状态解码可观测的对话系统中间状态的思路，有效解决了上述两个问题，为端到端任务型对话系统设计提供了一种切实可行的序列到序列学习框架。后续工作在其基础上加入了语义解析、系统对话动作等更多对话系统中间状态的解码[34-35]，进一步提高了端到端系统的可解释性。

1.2　研究问题与论文陈述

尽管端到端任务型对话系统的研究取得了不少进展，但仍然存在一些问题。在本论文中，我们总结了现有系统的两个主要问题，进行了研究与改进。

1.2.1　不支持多领域复杂对话建模

现有端到端系统大多是针对发生在某一个特定领域的单领域对话任务设计的[11,23-24,31-35]，难以推广到复杂的多领域、多需求对话场景。虽然在提供不同领

① 语义槽及其取值，例如”价格 = 便宜”

域的对话数据时，系统可以学习到不同领域任务的对话方式[33-35]，但由于缺乏领域识别能力，系统无法处理在一次对话中涉及到多个领域，在对话进行过程中出现领域及目标转换的复杂任务。例如，现有系统可以使用相应的对话数据训练分别完成预定餐厅和叫出租车的任务，但若用户希望在一次对话中进行餐厅预定之后直接租车，则无法处理。而在现实生活中，这种需要进行多领域切换的复杂任务型对话具有广泛的应用场景，例如剑桥对话研究组收集的游客中心对话数据中，包含餐厅推荐、酒店预定、约出租车、买火车票、景点查询、联系医院、联系警方等多达七个领域的对话场景，且一次对话中最多覆盖三个领域的不同任务。如何使端到端对话系统具备多领域复杂对话建模的能力，是目前对话系统研究领域的一个重点问题。

针对这个问题，我们提出了领域自适应的多级解码网络模型 DAMD（Domain-Aware Multi-Decoder Network），成功将端到端对话模型扩展到了复杂的多领域对话场景。DAMD 模型采用了一种新设计的对话状态和系统对话动作表示方法，实现了可进行领域自适应判定的对话状态跟踪和系统动作生成，同时克服了传统多领域对话系统状态、动作空间大，难以学习的缺点，具有很好的扩展性。

1.2.2　依赖标注数据进行训练

传统的模块化对话系统可以定义为一个部分可观测马尔可夫决策过程[13]（POMDP），在 POMDP 框架下定义的对话系统概率模型，可以明确规定用户输入、系统对话状态、对话动作、回复语句等变量之间的依赖与概率转移关系。然而，现有基于 Sequicity 框架的最新端到端对话模型，虽然展现出良好的性能，并通过引入从连续隐状态到可观测系统中间状态的解码，提供了一定的可解释性，但这类系统的研究中缺乏系统内各变量之间的概率建模分析，也没有成熟的理论框架支撑。通过对现有端到端模型的概率建模理论分析，我们发现对于任意一个对话轮次，在给定当前用户输入时，Sequicity 模型框架只分别建模了用户输入到对话状态和回复语句的条件概率，而缺少了（1）不同对话轮次的对话状态之间的转移概率建模；（2）对话状态和回复语句之间的依赖关系建模。在这种建模方式下，学习对话状态等系统中间状态变量的解码，只能采取有监督学习的方式进行。换言之，训练现有使用多级编解码器架构的端到端对话系统，需要使用大量标注了对话状态、系统对话动作等中间状态的对话数据，才能对各个解码器进行训练。在现实生活中每天产生大量任务型对话，对话数据相对容易收集，但对每一句话进行中间状态标注的代价很高，并且为了减少标注错误，标注者还需要掌握一定的对话系统工作原理。标注数据收集困难的问题，极大限制了这一类端到端系统的

应用前景。如何减少对于标注数据的依赖，是提高端到端系统实际应用价值所必须考虑的重要问题。

在本研究中，我们提出一种基于状态空间模型的对话模型框架，从理论上解决了现有 Sequicity 框架存在的问题。在新框架下，我们将系统对话状态和对话动作作为离散隐变量，引入端到端对话模型内部，并结合编解码器网络提出了离散状态端到端对话模型 DSNet（Discrete-State Network）。作为一种生成模型，DSNet 可以进行对话状态和对话动作等离散隐状态的无监督学习，对减少模型训练所需要的标注数据具有重要意义。最后，我们基于两种深度生成模型的隐变量推断方法，VAE[36-37] 和基于 RWS[38-39] 的，提出了 DSNet 在无隐状态标注时的无监督训练算法，并展示了如何结合少量对话状态和系统对话动作的标注数据，进行 DSNet 的半监督学习，有效利用无标注对话数据提升了端到端对话系统的整体性能。

1.3　论文组织结构

本论文的后续部分将按以下结构组织：

- 第2章介绍任务型对话系统以及本文所用到的机器学习的背景知识。
- 第3章介绍领域自适应的多级解码网络模型 DAMD，并展示 DAMD 如何解决复杂的多领域对话建模问题。此外，研究了任务型对话中同一对话上下文可能对应多种可行系统回复的“一对多”问题，并展示了如何基于 DAMD 进行多元化策略学习。
- 第4章从现有 Sequicity 框架下对话模型的概率建模分析出发，指出其不适用于无监督学习的原因，进而提出一种新的基于状态空间模型的对话模型框架作为解决方案。之后，在新框架下结合编解码器网络结构提出了离散状态端到端对话模型 DSNet，介绍了如何利用无标注数据进行 DSNet 的半监督学习。
- 第5章总结本论文的主要贡献以及讨论可行的未来研究方向。

第 2 章　研究背景和相关工作

本章对本论文研究工作的相关基础知识和现有研究进行介绍，包括任务型对话系统中的基本概念和端到端对话建模中使用的基本模型与方法等两部分内容。

2.1　任务型对话系统

如图1.2(a)所示，任务型对话系统包括自然语言理解、对话状态跟踪、对话策略选择和自然语言生成四个基本组成部分，以及提供外部知识的数据库用于信息查询。在语音对话系统中（Spoken Dialogue System）中，自然语言理解之前和自然语言生成之后还需要进行文本、语音之间的相互转换，即自动语音识别（Automatic Speech Recognition，ASR）和语音合成（Text To Speech，TTS）。本文只考虑以自然语言文本作为输入、输出的对话系统，不涉及语音方面的相关技术。接下来，我们将对任务型对话系统中的基本概念进行介绍。

2.1.1　对话领域知识本体

任务型对话系统中的本体（Ontology），规定了系统可以获取到的领域知识范围，换言之规定了系统可以处理的任务范围。在本体中给出了可在自然语言理解模块中识别出的语义槽（Slot）定义，包括告知语义槽（Informable Slot）和问询语义槽（Requestable Slot）两部分。其中，告知语义槽的取值（value）由用户告知系统，作为查询条件，系统在数据库中搜索满足告知语义槽相应取值的实体（Entity）。在确定实体后，用户可以询问该实体的其他信息，系统识别出相应的问询语义槽并在数据库中查询到其取值后，将用户的询问内容进行告知。

例如，在图2.1给出的剑桥餐厅查询数据库[11] 例子中，告知语义槽包括食物种类（food）、价格区间（pricerange）和所处地区（area）三个，问询语义槽包括以上三个告知语义槽，以及餐馆名称（name）、电话号码（phone）、邮政编码（postcode）和餐馆地址（address）共七个。数据库中的每一行对应一个餐馆，即一个实体，存储了该餐馆各个语义槽的取值信息。由该本体定义的任务型对话系统，可以识别用户对于餐馆食物种类、价格区间和所处地区的要求，帮助用户查找符合要求的餐馆，并对用户进一步询问餐馆地址、电话号码等问题进行回答。

name	food	pricerange	area	phone	postcode	address
Click here to define a filter						
the missing sock	international	cheap	east	01223 812660	c.b 25, 9 a.q	finders corner newmarket road
zizzi cambridge	italian	cheap	centre	01223 365599	c.b 2, 1 a.b	47-53 regent street
pizza hut fen ditton	italian	moderate	east	01223 323737	c.b 5, 8 w.r	cambridge retail park newmarket road
rajmahal	indian	moderate	east	01223 244955	c.b 5, 8 r.g	7 barnwell road fen ditton
yu garden	chinese	expensive	east	01223 248882	c.b 5, 8 p.a	529 newmarket road fen ditton
pipasha restaurant	indian	expensive	east	01223 577786	c.b 5, 8 p.a	newmarket road fen ditton
grafton hotel restaurant	british	expensive	east	01223 241387	c.b 5, 8 p.a	grafton hotel 619 newmarket road fen
curry prince	indian	moderate	east	01223 566388	c.b 5, 8 j.j	451 newmarket road fen ditton
pizza express fen ditton	italian	moderate	centre	01223 324033	c.b 5, 8 b.a	jesus lane fen ditton
la mimosa	mediterranean	expensive	centre	01223 362525	c.b 5, 8 a.q	thompsons lane fen ditton
meghna	indian	moderate	west	01223 727410	c.b 4, 3 l.f	205 victoria road chesterton
tandoori palace	indian	expensive	west	01223 506055	c.b 4, 3 l.e	68 histon road chesterton
golden wok	chinese	moderate	north	01223 350688	c.b 4, 3 h.l	191 histon road chesterton

图 2.1　剑桥餐厅查询数据库示意图

2.1.2　自然语言理解

自然语言理解模块的作用是对用户的输入语句进行解析与理解，一般包括语义槽值填充（Slot Filling）和用户意图判定（Intent Detection）两部分。

语义槽值填充

语义槽值填充即识别用户提到的各个告知语义槽及其取值的过程，能否正确进行槽值填充，是能否顺利完成用户查找目标的关键。进行语义槽值填充一般有两种方法，序列标注法或槽值分类法。在序列标注法中，语义槽值填充被抽象为一个序列标注问题，其目标是对一句话 $\mathbf{w} = (w_1, w_2, ..., w_T)$，找到每一个词 w_t 对应的语义槽标签 $\mathbf{s} = (s_1, s_2, ..., s_T)$，使得：

$$\hat{\mathbf{s}} = \arg\max_{\mathbf{s}} P(\mathbf{s}|\mathbf{w}) \tag{2-1}$$

使用序列标注法进行自然语言理解的常用模型包括隐马尔可夫模型[40]、条件随机场[41] 和基于卷积神经网络的模型[16,42-45] 等。

在槽值分类法中，语义槽值填充被抽象为一系列分类问题，对每一个语义槽在预先定义好的取值空间中进行分类：

$$\hat{v} = \arg\max_{v} P_s(v|\mathbf{w}) \quad \text{for } s \in \text{Ontology} \tag{2-2}$$

其中 s 表示语义槽，v 表示语义槽取值。槽值分类法常用基于神经网络的分类模型[18,46] 实现，由于固定取值空间为槽值填充带来了一定的先验信息，往往具有较高的识别准确率，但系统结构会根据语义槽取值范围发生变化，存在扩展性较差等问题。

用户意图识别

用户意图识别即将用户说的自然语言识别预先定义好的几种意图，属于句子分类任务。对一句话 $\mathbf{w} = (w_1, w_2, ..., w_T)$，用户意图识别的目标是找到一个意图类别 c，使得：

$$\hat{c} = \arg\max_{c} P(c|\mathbf{w}) \tag{2-3}$$

用户意图识别的意义在于，可以将状态空间近乎无穷的自然语言映射到只有几种有限状态的紧凑语义空间，降低系统后续处理的复杂度。用户意图识别可以应用 SVM[47] 或神经网络等模型[48-49] 解决，也可以和槽值填充同时进行[15,45]。

2.1.3　对话状态跟踪

对话状态跟踪是任务型对话系统的核心模块[50]，通过维护对话状态（Dialogue State）记录任务相关的对话历史信息，使系统具备多轮对话交互的能力。对话状态是对话进行到当前轮次时，所有告知语义槽取值的集合，除本体中规定的所有取值结果外，还包括“未提到”和“不关心”两种特殊取值可能。对话状态跟踪的过程如图2.2所示，在得到当前对话轮次用户输入的自然语言理解结果后，和系统上一轮对话状态中记录的对话历史信息综合并更新对话状态。

用户：你好，我要找餐馆！
对话状态：{食物种类=未提及，价格范围=未提及，所处地区=未提及}
系统：您今天想吃什么？ 用户：西餐。找个城西边的。
对话状态：{食物种类=西餐，价格范围=未提及，所处地区=城西}
系统：对不起，城西边没有西餐馆。别的地方可以吗？ 用户：好吧，那位置无所谓了。便宜一点就行。
对话状态：{食物种类=西餐，价格范围=便宜，所处地区=不关心}

图 2.2　对话状态跟踪示例

在系统实现时，由于对话状态跟踪需要语义槽值填充的结果，两者一般由同一个模型实现，即直接由当前的用户输入 $\boldsymbol{U}_t$ 和上一轮的对话状态 $\boldsymbol{B}_{t-1}$，得到新的对话状态 $\boldsymbol{B}_t$：

$$\boldsymbol{B}_t = \mathrm{DST}(\boldsymbol{U}_t, \boldsymbol{B}_{t-1}) \tag{2-4}$$

即使用同一个模型完成自然语言理解和对话状态跟踪[17-18,46,51-55]，取得了良好的效果。近期，针对传统对话状态跟踪模型需要预定义语义槽取值，扩展性差的问题[18,46,53]，研究者提出使用序列到序列模型动态生成对话状态的方法[56-57]，将槽值分类任务转化为槽值生成任务，词表中的所有词都可以成为潜在的语义槽取值，极大提升了模型的扩展性，同时也取得了很好的性能。由于对话状态跟踪的本质是对用户语句中任务相关词的语义识别与理解，随着 BERT[58] 等大规模预训练语言模型在捕捉语义信息能力方面的突破，基于 BERT 的对话状态跟踪模型也在近期获得了广泛关注，进一步提升了对话状态跟踪的性能[59-62]。

2.1.4　对话策略选择

对话策略选择模块和对话状态跟踪模块共同完成任务型对话系统多轮对话管理（Dialogue Management，DM）的核心功能[10,63]，其作用是根据当前的对话状态 $\boldsymbol{B}_t$ 和数据库查询结果 $\boldsymbol{DB}_t$，选择系统应该采用的对话动作 $\boldsymbol{A}_t$：

$$\boldsymbol{A}_t = \mathrm{DM}(\boldsymbol{B}_t, \boldsymbol{DB}_t) \tag{2-5}$$

对话动作（Dialogue Act）是自然语言语义的紧凑表达，一般由动作类型和语义槽值参数构成，例如“*告知（餐厅名称 =QQ 快餐，价格区间 = 中等）*”表示告知用户“QQ 快餐是一家价格适中的餐厅”，而“*问询（所在区域）*”可以表示“您对餐厅的位置有什么要求吗”。

在学习对话策略，也就是对话状态到系统对话动作的映射函数时，一般有最大似然和最大累计奖励两种方式。前者使用对话动作的标注数据对判别式模型 $\boldsymbol{P}(\boldsymbol{A}_t|\boldsymbol{B}_t, \boldsymbol{DB}_t)$ 进行有监督学习[18,64-66],后者则采用强化学习算法进行训练[20,67-68]。

2.1.5　自然语言生成

最后，系统对话动作还需要在自然语言生成模块中转化为可供人理解的自然语言，呈现给用户。回复语句生成的过程可以形式化为：

$$\boldsymbol{R}_t = \mathrm{NLG}(\boldsymbol{A}_t) \tag{2-6}$$

自然语言生成的主流方法分为两大类。第一类是基于检索的方法，将 NLG 抽象为一个分类问题，从预先准备好的回复候选句子中选择概率最大的句子作为回复[69-71]。由于系统回复只能从预先准备好的候选句子中产生，需要人工构建有足够大的候选句子集以覆盖可能出现的各种回复，扩展性较差。第二类是基于生成的方法，使用循环神经网络等模型逐词生成回复语句[18,21-22,32,72]。基于生成的方

法虽然有可能生成不符合语法的句子，比基于检索的方法可控性差，但其完全依靠数据驱动，鲁棒性和迁移能力较强。

去词汇化

去词汇化[21]（Delexicalization）是自然语言生成时的一种技巧，指在生成包含语义槽取值的回复语句时，将语义槽的具体值替换为统一的值标识符，使自然语言生成的内容与数据库中的具体槽值无关。例如，在生成回复语句“QQ 快餐是一家价格适中的餐厅”时，去词汇化的 NLG 模型生成的是“<name> 是一家价格 <pricerange> 的餐厅”，再通过数据库查询结果得到 <name> 和 <pricerange> 的具体取值，进行后处理。这样做的好处是可以让 NLG 模型专注于生成任务型对话的句式而非关注语义槽取值的词本身，做到语言和领域知识的解耦，有效降低 NLG 模块的学习难度。

2.2　端到端对话建模

端到端对话建模的思想是直接学习从用户输入到系统回复输出的映射关系，将任务型对话抽象为一个序列到序列学习问题，进行端到端的联合训练。在本节中，我们将对序列到序列学习的一些基本方法，以及它们在端到端对话建模中的应用进行介绍。

2.2.1　循环神经网络

循环神经网络（Recurrent Neural Network，RNN）是一类具有按时序有向连接的循环神经元结构的人工神经网络模型。通过使用其内部状态（隐层状态）来存储、传递输入序列的时序信息，RNN 可以对序列数据进行有效建模，在语言建模[73]、机器翻译[74]、语音识别[75] 等序列数据的建模任务上取得了广泛应用。一种广泛使用的 RNN 体系结构是 Elman 类型的 RNN[76]，如图2.3所示，其通过循环连接将时刻 $t-1$ 处模型隐层输出反馈给下一时刻 t 处的同一隐层，从而将从初始时刻到当前时刻的输入序列信息浓缩存储在了当前时刻的隐层状态中。具体来讲，当前时刻的输入向量和上一时刻的隐层向量首先进行加权和，再通过一个可微的非线性激活函数变换后，即可得到得到当前时刻的隐层状态向量：

$$h_t = f(Ux_t + Vh_{t-1} + b) \tag{2-7}$$

其中 f 表示非线性激活函数。RNN 模型在训练时，神经网络参数可以通过基于最大似然准则得到的损失函数进行优化，使用 BPTT（Back-Propagation Through Time）

算法进行各时刻隐状态之间梯度的反向传播，将输出层计算得到的损失通过循环连接传播到之前的各个时刻，进行权重矩阵的参数更新。

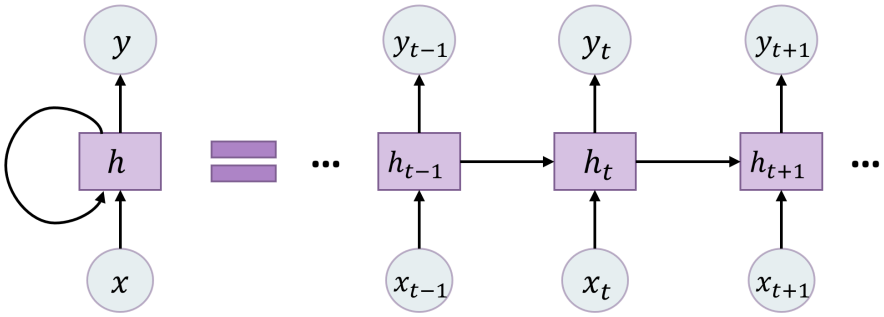

图 2.3　循环神经网络展开结构示意图

LSTM

传统的 RNN 模型虽然理论上可以建模任意长的时间序列信息，但由于其存在梯度爆炸和梯度消失问题[77]，在实际应用时难以保留长序列信息，极大限制了 RNN 在序列建模中的应用。长短时记忆网络 LSTM[78]（Long Short-Term Memory）是针对该问题提出的一种改进版 RNN 模型。LSTM 使用一组额外的状态向量 C_t 存储长时记忆信息，并引入门机制，决定每一时刻的输入有哪些应该被记住，当前记忆的信息中有哪些已不再重要该被遗忘，又有哪些该被送入下一时刻，其计算公式如下：

$$
\begin{aligned}
f_t &= \sigma(U_f x_t + W_f h_{t-1}) \\
i_t &= \sigma(U_i x_t + W_i h_{t-1}) \\
\tilde{C}_t &= \tanh(U_c x_t + W_c h_{t-1}) \\
C_t &= f_t * C_{t-1} + i_t * \tilde{C}_t \\
o_t &= \sigma(U_o x_t + W_o h_{t-1}) \\
h_t &= o_t * tanh(C(t))
\end{aligned}
\tag{2-8}
$$

其中 σ 表示 sigmoid 激活函数，$*$ 表示逐元素点积。门机制的引入显著提高了序列信息的长时间记忆能力，且由于损失的反向传播也受到门的控制，有效缓解了梯度经过长时间传递的爆炸或消失问题。

GRU

GRU[26]（Gated Recurrent Unit）也是针对梯度爆炸和梯度消失问题提出的一种 RNN 变体结构。GRU 利用了和 LSTM 相似的门机制，但对模型结构进行了精简，不引入额外的状态向量 C_t，且将遗忘门 f_t 和输入门 i_t 进行了合并。其计算公式如下：

$$\begin{aligned} z_t &= \sigma(U_z x_t + W_z h_{t-1}) \\ r_t &= \sigma(U_r x_t + W_r h_{t-1}) \\ \tilde{h}_t &= \tanh(U_h x_t + W_h(r_t * h_{t-1})) \\ h_t &= (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t \end{aligned} \tag{2-9}$$

相比于 LSTM，GRU 具有结构简单、参数数量更少的优点，能够在训练过程中更快地收敛。在本研究中，我们使用 GRU 作为序列建模的基本模型。

2.2.2　序列到序列学习

序列到序列模型[25-26]（Seq2Seq）是自然语言处理任务中应用最普遍的一类条件生成模型，其作用是在给定输入序列 X 的条件下，对输出序列 Y 的条件概率 $P(Y|X)$ 进行建模。一个典型的 Seq2Seq 模型由编码器（Encoder）和解码器（Decoder）两个 RNN 组成①，其中编码器 RNN^{enc} 将输入序列 X 编码为隐状态向量表示，之后解码器 RNN^{dec} 通过这些隐状态向量，预测输出序列 Y。令 w_i^X 和 w_j^Y 分别表示输入序列的第 i 个词和输出序列的第 j 个词，设 $h_0^{enc} = 0$，则编码过程可以表示为循环计算：

$$h_i^{enc} = \text{RNN}^{enc}(w_i^X, h_{i-1}^{enc}) \tag{2-10}$$

编码器的最后一个隐状态 $h_{|X|}^{enc}$ 综合了整个 X 序列的信息，即作为 X 的向量表示，输入解码器用作初始隐状态 h_0^{dec}。然后，解码器通过以下公式依次预测序列 Y 的输出词：

$$h_j^{dec} = \text{RNN}^{dec}(w_j^Y, h_{j-1}^{dec}) \tag{2-11}$$

$$o_j = \text{Softmax}(W h_j^{dec} + b) \tag{2-12}$$

其中 o_j 是时刻 j 词表中每一个词的输出概率。此外，特殊符号 <SOS> 和 <EOS> 常被添加在句子 Y 的首尾，以便让模型学会预测目标句子的第一个字符，以及学

① 本研究中使用 RNN 作为编、解码器网络，但 Seq2Seq 模型的编、解码器网络结构并不只局限于 RNN，而是可以任意选取。

会终止预测的时机。

注意力机制

尽管 Seq2Seq 模型在理论上具有学习长序列之间依赖关系的能力，在实际应用过程中其表现并不尽如人意。针对该问题，研究者提出了注意力机制[26,28]（Attention），大大提高了 Seq2Seq 模型对长序列的条件建模能力。注意力机制的思想是，不再用编码器 RNN 的最后一个隐状态这一个固定维度向量作为整个序列信息的概括，而是使用解码器 RNN 的隐状态去所有时刻的编码器隐状态中进行动态读取，形成一个加权的输入信息向量，作为源序列 X 的上下文编码表达。记 $H^{enc} = h_1^{enc}, ..., h_{|X|}^{enc}$ 为编码器 RNN 的所有时刻的隐状态向量，则解码器每一时刻的解码过程可以表示为：

$$h_j^{dec} = \mathrm{RNN}^{dec}(w_j^Y, h_{j-1}^{dec}) \tag{2-13}$$

$$\tilde{\alpha}_j^i = f(h_i^{enc}, h_j^{dec}) \tag{2-14}$$

$$\alpha_j = \mathrm{Softmax}(\tilde{\alpha}_j) \tag{2-15}$$

$$c_j = \sum_i \alpha_j^i h_i^{enc} \tag{2-16}$$

$$o_j = \mathrm{Softmax}(W[h_j^{dec}; c_j] + b) \tag{2-17}$$

其中 f 是度量向量相似度的函数，可以取点积、线性映射或神经网络等形式[28]，用于计算注意力得分 $\tilde{\alpha}$，再进行归一化后加权编码器隐状态向量得到上下文编码向量 c_j，如图2.4所示。

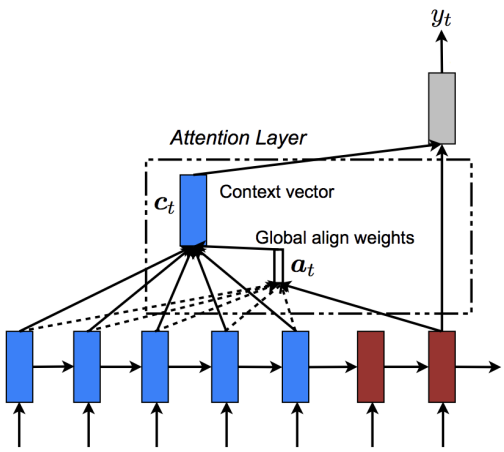

图 2.4　编解码器网络模型中的注意力机制（图引自[28]）

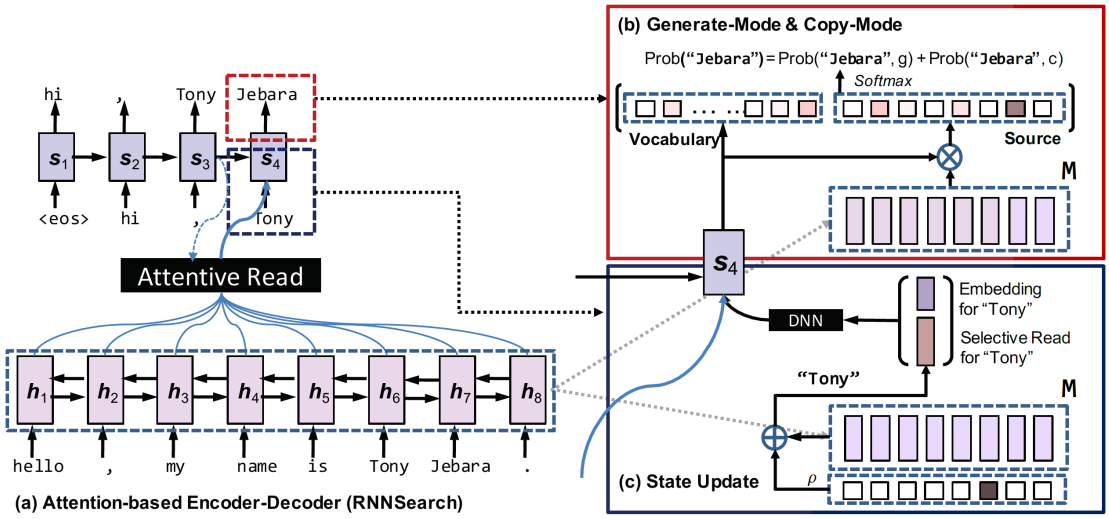

图 2.5　引入拷贝机制的序列到序列学习模型（图引自[79]）

拷贝机制

拷贝机制[79]（Copy Mechanism）是注意力机制的进一步拓展，让 Seq2Seq 模型在解码目标序列时具备了从源序列中拷贝单词的能力。加入拷贝机制后，解码器隐状态不仅仅用来计算生成词表上各个单词可能性的得分，还会用再和源序列每一时刻的编码器隐状态重新计算一次注意力，计算源序列每一时刻对应单词的拷贝得分，和生成得分综合计算输出词的概率分布，如图2.5所示。其中各概率的计算方式如下：

$$P_{gen}(y_j = v_k) = \frac{1}{Z}([h_j^{dec}; c_j]^{\mathsf{T}} W_g v_k^{onehot}) \tag{2-18}$$

$$P_{copy}(y_j = x_i) = \frac{1}{Z}([h_j^{dec}; c_j]^{\mathsf{T}} W_c h_i^{enc}) \tag{2-19}$$

$$P(y_j) = \begin{cases} P_{gen}(y_j) + P_{copy}(y_j) & y_j \in X \cap V \\ P_{gen}(y_j) & y_j \in \bar{X} \cap V \\ P_{copy}(y_j) & y_j \in X \cap \bar{V} \\ P_{gen}(\langle unk \rangle) & y_j \in \bar{X} \cap \bar{V} \end{cases} \tag{2-20}$$

其中 $P_{gen}(y_j = v_i)$ 表示生成词表中第 k 个词的概率，v_k^{onehot} 是该词的 onehot 指示向量；$P_{copy}(y_j = x_i)$ 是拷贝源序列中第 i 个词的概率，Z 是保证 $P(y_j)$ 满足概率分布要求的归一化系数。在生成概率和拷贝概率相加时，分为四种情况：1）对于同时在词表中和源句子中的词，最终的解码概率是生成概率和拷贝概率的和；2）对于只在词表中，没有在源句子中的词，最终的解码概率就等于生成概率；3）对于只在源句子中，没有在词表中的词，最终的解码概率就等于拷贝概率；4）对于既没

有在源句子中，也没有在词表中的词，最终解码概率等于用于标志未录入词的特殊符号 $\langle unk \rangle$ 的生成概率。由此可以看出，引入拷贝机制后，Seq2Seq 模型具备了复制训练集中不常出现的稀有词甚至词表外单词的能力，在实际应用中具有重要意义。此外，由于引入拷贝机制可以使模型倾向于拷贝源句子的词，对于文本摘要等具备拷贝属性的任务表现出很大幅度的性能提升[25]。在任务型对话系统中，由于进行对话状态跟踪恰好需要拷贝用户的语义槽值，在系统回复中也经常出现用户表达的引用，拷贝机制取得了很好的效果[70]，在目前最先进的端到端对话系统中取得了广泛应用[33-35]。

2.2.3　基于多级编解码器的端到端对话模型

最后我们介绍和本论文工作最为相关的一类端到端对话模型，结合拷贝机制的多级编解码器网络模型[33-35]。通过将 Seq2Seq 模型中的隐状态显示解码为任务型对话系统的中间状态（NLU 解析结果、对话状态、系统对话动作），这一类系统可以像传统任务型对话系统一样查询数据库，且具有较好的可解释性。

Sequicity 建模框架

结合拷贝机制的多级编解码器模型框架 Sequicity[33]，其基本思想是在使用基于拷贝机制的 Seq2Seq 模型建模用户输入到系统回复输出的基础上，加入了另一个基于拷贝机制的解码器，用于进行对话状态的解码，如图2.6所示。为了进行用户输入到对话状态的 Seq2Seq 学习，Sequicity 设计了一种使用单词序列表示的对话状态，只记录用户提到的所有语义槽取值，称为信度序列（Belief Span）。在获得信度序列后，再通过后处理，将生成的语义槽取值和语义槽进行对应，得到对话状态。为了避免引入过多概念造成混乱，我们在之后仍统称为对话状态的解码。由于多轮对话中经常出现省略上下文的情况，Sequicity 将上一轮的系统回复 $\boldsymbol{R}_{t-1}$ 和本轮的用户输入 $\boldsymbol{U}_t$ 共同作为当前的对话内容输入，记 $\boldsymbol{C}_t = \{\boldsymbol{R}_{t-1}, \boldsymbol{U}_t\}$。系统回复及对话状态的解码过程如下：

$$h_{C_t}^{enc} = \mathrm{RNN}_C^{enc}(\boldsymbol{R}_{t-1}, \boldsymbol{U}_t) \tag{2-21}$$

$$h_{B_t}^{dec} = \mathrm{RNN}_B^{dec}(h_{C_t}^{enc}, h_{B_{t-1}}^{dec}) \tag{2-22}$$

$$\boldsymbol{B}_t = \mathrm{CopyDecode}(h_{B_t}^{dec}, h_{C_t}^{enc}, h_{B_{t-1}}^{dec}) \tag{2-23}$$

$$\boldsymbol{DB}_t = \mathrm{DataBaseSearch}(\boldsymbol{B}_t) \tag{2-24}$$

$$h_{R_t}^{dec} = \mathrm{RNN}_R^{dec}(h_{C_t}^{enc}, h_{B_t}^{dec}, \boldsymbol{DB}_t) \tag{2-25}$$

$$\boldsymbol{R}_t = \mathrm{CopyDecode}(h_{R_t}^{dec}, h_{C_t}^{enc}, h_{B_t}^{dec}) \tag{2-26}$$

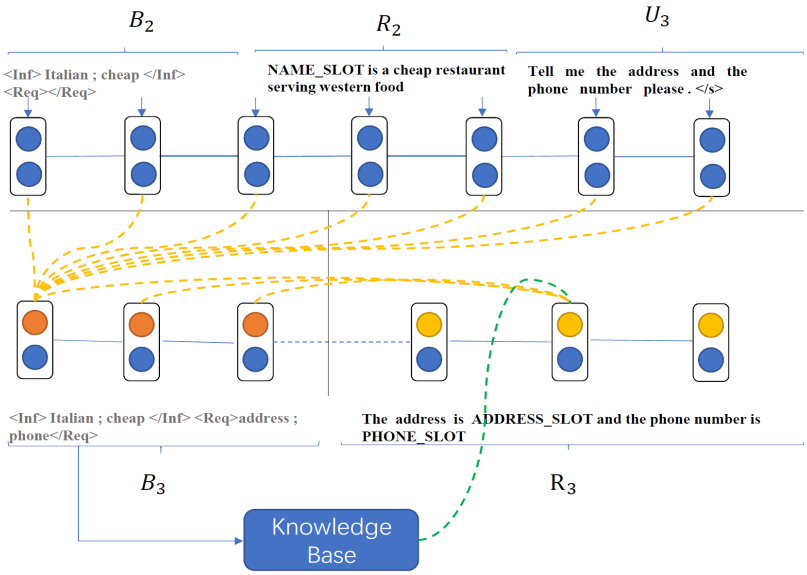

图 2.6　Sequicity 多级编解码器框架示意图（图引自[33]）

其中 $CopyDecode(\cdot)$ 表示基于拷贝机制的单词序列解码过程，$DataBaseSearch$ 表示数据库查询操作。计算得到每一轮对话状态 $\boldsymbol{B}_t$ 的隐状态后，会在下一轮对话中作为解码新对话状态的输入，以实现对话状态的多轮跟踪。$\boldsymbol{DB}_t$ 是数据库查询结果，由于 Sequicity 生成的是在2.1.5节介绍过的去词汇化系统回复 $\boldsymbol{R}_t$，因此生成 $\boldsymbol{R}_t$ 时不需要数据库中查询到实体的具体语义槽取值信息，只需要知道符合要求的实体数量即可。因此，在 Sequicity 中，$\boldsymbol{DB}_t$ 被转化为一个 5 维的 one-hot 向量，分别表示数据库中找到 0、1、2、3 或大于 3 个匹配的结果，输入 $\boldsymbol{R}_t$ 解码器控制系统回复语句的生成。

Sequicity 首次将端到端任务型对话建模统一在了一个 Seq2Seq 框架内，并且得益于拷贝机制的引入，取得了良好的对话跟踪和系统回复生成性能。然而，由于 Sequicity 在解码对话状态时只解码用户提到的语义槽取值，只适用于语义槽差别较大的任务，例如上面提到的订餐例子。而当存在语义相近的槽时，这种方法容易出现混淆，例如在订车票任务中，用户提到的一个时间既可能是出发时间也可能是到达时间。另一方面，Sequicity 只建模了对话状态和系统动作，即任务型对话系统中四个模块中的两个，将系统对话动作的建模隐含在了系统回复的生成中，在对话策略学习方面具有可提升空间。

近期研究进展

近期的研究工作对 Sequicity 框架进行了拓展，加入了任务型对话系统的更多组件，进一步提升了系统性能[34-35]。这些模型均沿用了 Sequicity 框架下的结合拷贝机制的多级编解码器模型结构，通过引入更多解码器，建模更加丰富的系统中

间状态，各模型的结构区别如图2.7所示。

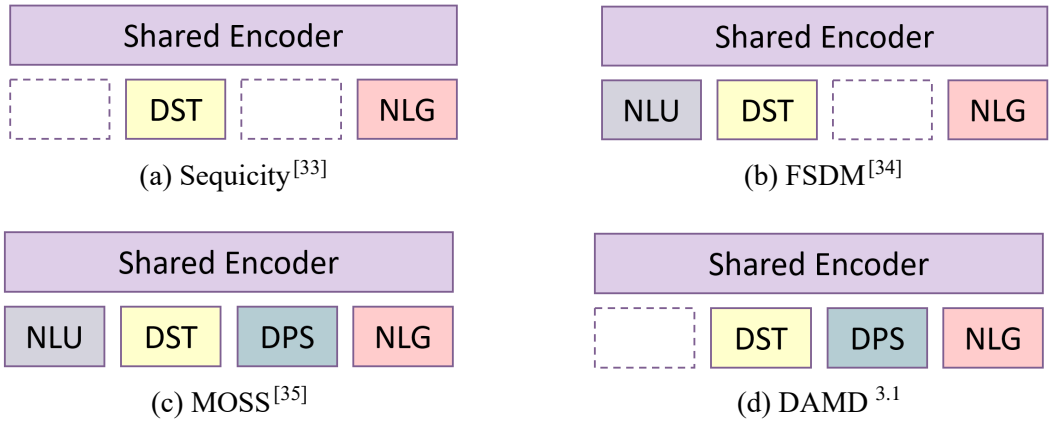

(a) Sequicity[33]　(b) FSDM[34]　(c) MOSS[35]　(d) DAMD [3.1]

图 2.7　基于多级编解码器的端到端对话模型结构对比

随着加入更多解码器，端到端对话模型的回复语言流畅性和任务完成率都得到了提升。然而，由于各个解码器都需要提供相应的标注数据进行训练，例如训练对话状态解码器需要每轮对话的对话状态标注，训练对话动作解码器需要系统回复的对话动作标注，数据标注的巨大开销严重限制了这一类模型的实际应用。另一方面，现有系统只考虑了对话过程中不存在领域转换的单领域对话，缺乏对复杂的多领域任务型对话进行端到端建模的探索。

第 3 章　多领域任务型对话建模

在多领域对话中，由于用户可能会在几个领域的不同任务目标中进行切换，往往会产生更多的对话轮数。此外，由于多领域对话的领域知识本体更为复杂，语义槽值数量多，对话状态和系统对话动作空间都更加复杂，这些都大大增加对话系统进行对话状态跟踪和规划对话策略的难度。针对这些困难，我们提出了领域自适应的多级解码网络模型 DAMD（Domain-Aware Multi-Decoder Network），以解决现有端到端任务型对话系统不适合于建模包含领域转换的复杂多领域对话的问题。

另一方面，对话自然存在的“一对多”的现象，即同一语境可以存在多种合理但不同的回复方式[80-81]，在自由度更高的多领域对话中尤为明显，很大程度上影响了系统对话策略的学习。我们利用 DAMD 模型的 Seq2Seq 特性，研究了任务型对话中的“一对多”问题，提出了一种数据增强方法，成功让 DAMD 模型学习到了更加多元化的对话策略，充分展现了 DAMD 模型在多领域任务型对话建模中的灵活性。

本章接下来将分别介绍 DAMD 模型的结构与原理，在多领域任务型对话数据集上的性能评估，以及如何使用 DAMD 模型进行多元化策略学习。

3.1　领域自适应的多级解码网络模型

DAMD 模型沿用了 Sequicity 的 Seq2Seq 学习基本框架，使用三个不同解码器依次解码对话状态、系统对话动作和系统回复语句。针对多领域对话的特点，DAMD 重新设计了包含领域指示词的对话状态词序列，可以做到领域自适应，以处理多领域对话问题。同时，为了进行对话策略的 Seq2Seq 学习，我们提出了词序列形式的对话动作，在学习多领域对话中的复杂对话策略时具有动作空间复杂度低、可进行领域知识共享等优势。DAMD 模型的整体结构如图3.1所示，下面将按照其工作原理依次对各部分进行介绍。

领域知识共享的去词汇化方法

DAMD 模型的输入是经过去词汇化（定义见2.1.5节）处理的对话数据，以降低自然语言的多样性，减小学习难度。在传统的多领域对话去词汇化方法中，不同领域中相同的语义槽取值会被替换为不同的值标识符，无法进行领域之间的知识共享[82-83]。例如，在餐厅、旅店等领域都存在“电话号码”、“地址”等语义槽，以电话号码为例，在传统的去词汇化过程中，其具体值会被分别替换成 <restaurant.phone>

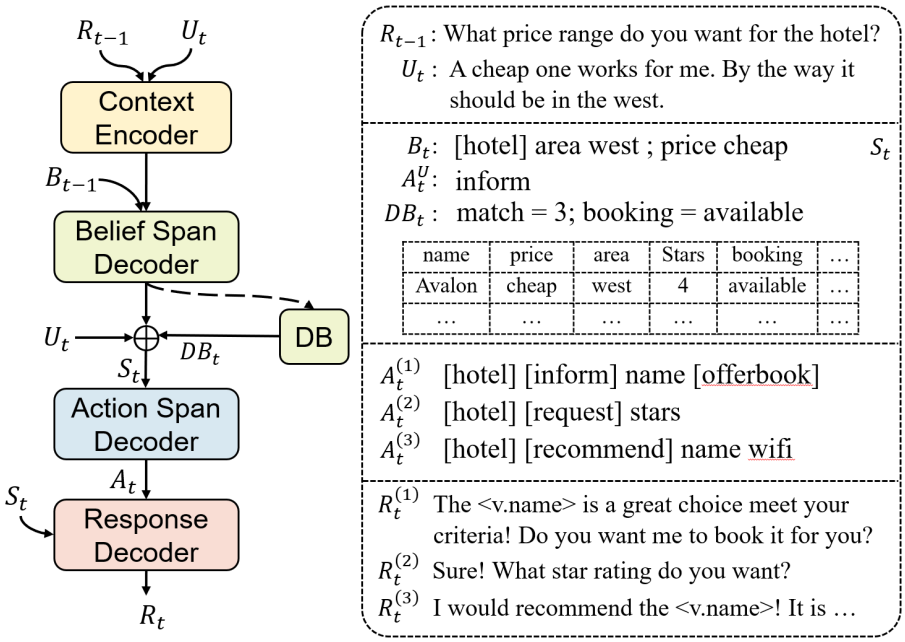

图 3.1　DAMD 模型结构及系统各中间状态示例

和 <hotel.phone>，系统需要通过两个领域的对话数据，分别学习这两种值标识符的理解与生成规律。而我们在去词汇化时，直接将具有相同语义槽的值替换为相同的值标志符（<phone>），从而使得所有提到该语义槽的对话都可以共享标志符的信息，便于学习。在后处理过程中将值标志符由数据库中的语义槽具体取值填充时，由于我们的模型可以自适应确定对话领域，因此使用相同的值标识符也不会产生歧义。

对话状态解码

DAMD 模型中编码器的使用方法以及对话状态解码的公式和 Sequicity 相同，由每一轮的用户语句、上一轮的系统回复和上一轮对话状态的隐状态向量共同决定当前对话状态：

$$h_{C_t}^{enc} = \mathrm{RNN}_U^{enc}(\boldsymbol{R}_{t-1}, \boldsymbol{U}_t) \tag{3-1}$$

$$h_{B_t}^{dec} = \mathrm{RNN}_B^{dec}(h_{C_t}^{enc}, h_{B_{t-1}}^{dec}) \tag{3-2}$$

$$\boldsymbol{B}_t = \mathrm{Decode}(h_{B_t}^{dec}) \tag{3-3}$$

两者的差别在于 $\boldsymbol{B}_t$ 的表示形式。在 DAMD 模型的对话状态中，除了解码语义槽值之外，还需要额外解码领域名和语义槽名，指示语义槽值对应的具体领域和属性。例如一个包含找餐厅和订出租两个领域的对话状态“[restaurant] name Curry Garden ; time 18:00 [taxi] leave 20:00 ; destination Kings Street”中，可以清楚区分餐

厅领域的“名称”和“订餐时间”与出租领域的“目的地”和“离开时间”等语义槽取值，避免了不同领域的相同语义槽、同一领域语义相近的槽之间的混淆。若像 Sequicity 中只解码“Curry Garden ; 18:00 ; 20:00 ; Kings Street”等语义槽值，则在后处理时难以区分地点和时间的意义，无法进行数据库查询。

在增加了领域指示符后，模型可以自动学习包含多个领域的语义槽值，在不增加复杂度的情况下同时跟踪各个领域的对话状态。同时，通过比较当前轮对话和上一轮对话中各个领域对话状态的变化，可以自动确定当前对话所处的领域：有对话状态变化的领域即为当前对话所处的领域，而没有对话状态变化（用户可能在进行询问等动作），则延续上一轮对话的领域不变，从而实现了对话领域的自适应判定。

系统对话动作解码

在对话状态更新后，需要进行数据库查询得到查询结果的 one-hot 编码向量 $\boldsymbol{DB}_t$，和对话状态、用户语句的隐状态共同用于解码系统对话动作：

$$\boldsymbol{DB}_t = \text{DataBaseSearch}(\boldsymbol{B}_t) \tag{3-4}$$

$$h_{A_t}^{dec} = \text{RNN}_A^{dec}(h_{C_t}^{enc}, h_{B_t}^{dec}, \boldsymbol{DB}_t) \tag{3-5}$$

$$\boldsymbol{A}_t = \text{Decode}(h_{A_t}^{dec}) \tag{3-6}$$

为了在 Seq2Seq 框架下进行解码，系统对话动作采用和对话状态相似的单词序列形式，由按顺序排列的领域名、动作名和语义槽名组成。例如，一个系统对话动作“餐厅领域-告知（价格）”可以表示为由三个词（标识符）组成的序列“[餐厅] 告知价格”。这种表示方法的好处是将在所有领域、动作、语义槽组合形成的庞大状态空间上的对话动作分类问题，转化为可选词表很小的序列解码问题，大大降低了系统学习对话策略的难度。此外，由于对话动作和对话状态的形式相同，且均为单词序列，解码领域标识符、语义槽名时可以受益于拷贝机制，取得更高的系统对话动作预测准确率。

系统回复解码

最后一步是基于之前的解码结果生成系统回复语句：

$$h_{R_t}^{dec} = \text{RNN}_B^{dec}(h_{C_t}^{enc}, h_{B_t}^{dec}, h_{A_t}^{dec}, \boldsymbol{DB}_t) \tag{3-7}$$

$$\boldsymbol{R}_t = \text{Decode}(h_{R_t}^{dec}) \tag{3-8}$$

不同于传统任务型对话系统中系统回复语句的解码只依赖与对话动作 A_t，DAMD 会在最后的系统回复解码器中对之前得到的所有隐状态所包含的信息进行综合，由模型自动选择发挥作用的信息，更加符合端到端的建模思想。

模型训练

在训练时，DAMD 模型仍然采用了有监督学习的方式进行三个解码器的训练：使用数据集中的对话状态、系统对话动作和标准系统回复提供的标签和解码器生成的概率分布计算交叉熵并相加，得到最终的损失函数，进行端到端的联合优化。

3.2　模型性能评估

我们在近期发布的多领域任务型对话数据集 MultiWOZ[82] 上进行了 DAMD 模型的性能评估。本节将对 MultiWOZ 数据集、基于数据集的对话系统自动评价指标、DAMD 模型的实现细节以及进行对比的其他基线模型进行介绍，并对评估结果进行讨论分析。

3.2.1　数据集与评价指标

MultiWOZ 是剑桥对话研究组收集的游客和客服之间的多领域人人对话数据集，包括预定餐厅、酒店、火车票、出租车、寻找景点、找医院、叫警察等七个领域的 10438 个对话样本（训练集 8438 个/开发集 1000 个/测试集 1000 个），且每个对话样本可涉及多达三个对话领域的转换。从图3.2展示的统计信息可以看出，MultiWOZ 是同类数据集中规模最大的，且具有最为复杂的领域知识本体，对话中的词汇表达多样性高、长句较多，大大增加了对话建模的难度。

Metric	DSTC2	SFX	WOZ2.0	FRAMES	KVRET	M2M	MultiWOZ
# Dialogues	1,612	1,006	600	1,369	2,425	1,500	**8,438**
Total # turns	23,354	12,396	4,472	19,986	12,732	14,796	**115,424**
Total # tokens	199,431	108,975	50,264	251,867	102,077	121,977	**1,520,970**
Avg. turns per dialogue	14.49	12.32	7.45	**14.60**	5.25	9.86	13.68
Avg. tokens per turn	8.54	8.79	11.24	12.60	8.02	8.24	**13.18**
Total unique tokens	986	1,473	2,142	12,043	2,842	1,008	**24,071**
# Slots	8	14	4	**61**	13	14	25
# Values	212	1847	99	3871	1363	138	**4510**

图 3.2　任务型对话数据集的统计信息对比（图引自[82]）

在该数据集上进行对话系统的评估，共有 4 个自动评价指标：

- 查找准确率（inform rate）：对话系统提供了正确的实体（符合用户要求的餐厅、旅馆等）的对话所占比例，用于评价系统把握用户任务目标的能力。

- 对话完成率（success rate）：对话成功完成，暨用户所有需求都得到正确回应的对话所占比例，用于评价系统对用户需求的回应能力。
- BLEU 得分：系统生成回复和数据集中的标准回复之间的相似度，用于评价系统回复生成的质量。
- 综合得分：前三项指标按 (inform + success) $*$ 0.5 + BLEU 计算的加权得分

其中，前三个指标是随 MultiWOZ 数据集一起提出的多领域任务型对话生成标准评测指标，最后一个加权得分参照论文[84] 中的计算方法。

3.2.2　实现细节与基线模型介绍

我们使用一个层数为 1、隐层神经元数量为 100 的双向 GRU 模型作为 DAMD 模型的编码器，以及三个具有相同隐层神经元数量的标准 GRU 分别作为对话状态、系统对话动作和回复语句的解码器。词表大小设置为 3000，输入词向量的维度为 50。我们使用 Adam 优化器[85] 进行模型训练，初始学习速率为 0.005，若连续 3 个训练周期损失不下降，则学习速率减半，连续 5 个训练周期损失不下降，则停止训练。

我们使用 5 种基准模型进行了实验，与 DAMD 模型进行对比：

- Seq2Seq + Attn：结合注意力机制的 Seq2Seq 模型，也是 MultiWOZ 数据集给出的对话生成评测的基准模型[82]。
- Seq2Seq + Copy: 结合拷贝机制的 Seq2Seq 模型。
- MD-Sequicity: DAMD 模型去除系统对话动作解码器的简化版本，和 Sequicity 的区别在于将原对话状态状态替换成了我们提出的领域自适应对话状态。
- SFN + RL[84]: 由几个经过预训练的对话编解码器网络组成，不同网络之间通过隐状态连接的 seq2seq 模型。在使用有监督学习训练之外，还使用了强化学习（Reinforcement Learning，RL）进行模型微调。SFN 和 DAMD 模型的共同点在于，均为建模了对话状态和系统对话动作的端到端对话模型，但区别在于 SFN 使用二元指示向量表示对话状态和系统对话动作，并且没有引入拷贝机制。
- HDSA[83]: 使用多级自注意力网络[86]（Transfomer），是 MultiWOZ 目前性能最佳的模型。HDSA 提出了一种图结构（graph）的系统对话动作，首先基于 BERT[58] 进行系统对话动作预测，使用动作预测结果控制自注意力网络的结构，再生成系统回复。

所有模型使用 MultiWOZ 的训练集进行训练，使用开发集上的结果进行调参，在测试集上计算各评价指标进行评估。

3.2.3　实验结果与分析

实验结果如表3.1所示。其中，generated 表示使用模型自己预测的系统对话动作进行，oracle 表示使用真实对话动作（数据集中提供了相应的标签），结果按照是否建模对话动作以及使用预测或者真实的系统对话动作分为了三组，每组内模型得到的最好结果进行了加粗表示。最后一行是使用数据集的标准回复计算得到的各项评价指标，代表模型可能达到的最好性能水平，其中任务完成度没有达到 100% 的原因在于数据集中存在少量标注错误噪声。

模型	系统对话动作		Inform	Success	BLEU	综合得分
	种类	形式	(%)	(%)		
1. Seq2Seq + Attn[82]	-	-	71.3	61.0	**18.9**	85.1
2. Seq2Seq + Copy	-	-	86.2	**72.0**	15.7	94.8
3. MD-Sequicity	-	-	**86.6**	71.6	16.8	**95.9**
4. SFN + RL[84]	generated	one-hot	82.7	72.1	16.3	93.7
5. HDSA[83]	generated	graph	82.9	68.9	**23.6**	99.5
6. DAMD	generated	span	89.2	**77.9**	18.6	**102.2**
7. SFN + RL[84]	oracle	one-hot	-	-	29.0	106.0
8. HDSA[83]	oracle	graph	87.9	78.0	**30.4**	113.4
9. DAMD	oracle	span	**95.4**	**87.2**	27.3	**118.5**
标准回复	oracle	-	96.6	94.2	100	195.4

表 3.1　MultiWOZ 上各对话模型的回复生成结果对比

第一组实验中（第 1-3 行）模型性能的对比结果表明，拷贝机制的应用可以显著提高 Seq2Seq 对话模型的任务完成能力（查找准确率和任务完成率），而在应用领域自适应的对话状态表示后，综合得分又取得了进一步的提高。然而，表征语言相似度的 BLEU 得分有所下降，这可能是由于引入更多结构化先验信息后（拷贝、对话状态解码），模型更加偏重于学习对话中任务相关的信息，减少了对语言本身的关注。在建模系统对话状态的模型中（第 4-9 行），无论是否提供真实的系统对话动作标签，DAMD 模型都显著好于其他基线模型，尤其是在任务型对话最重要的任务完成能力相关指标上取得了显著提高，说明了我们系统对话动作建模方式的优越性。通过 MD-Sequicity（第 3 行）与 DAMD（第 6 行）的对比可以看出，增加系统对话动作的建模可以全方位提高模型的性能。在 BLEU 得分方面，DAMD 模型也高于同使用 RNN 作为编、解码器的 SFN 模型，而 RNN 和 Transfomer 模型本身的特征提取能力差距[86]，是造成 DAMD 模型的 BLEU 得分不如 HDSA 的主要原因。提供真实的系统对话动作标签后，各模型的性能都有显著提高，表明系统对话动作的预测错误较多，严重影响最后的系统回复生成质量。值得注意的是，

DAMD 模型在使用真实系统对话动作标签的情况下（第 9 行），查找准确率达到了 95.4%，已经非常接近标准回复的 96.6%，表明我们的模型在用户需求把握方面的优越性能。

对话动作解码错误示例	用户: I will be going from Cambridge to Birmingham New Street. 标准系统对话动作：[request] day	用户: Yes, i would like a reservation. 标准系统对话动作：: [request] people
	对话动作解码结果： [request] leave [request] leave arrive [inform] choice [request] leave [inform] choice [request] leave arrive [inform] id arrive destination [offerbook]	对话动作解码结果： [offerbook] [offerbook] [general] [reqmore] [inform] food area name [offerbook] [inform] address name [offerbook] [inform] food area name [reqmore]
自然语言生成错误示例	对话动作: [recommend] name [inform] postcode address [reqmore] 系统回复: I would suggest the <name>. The postcode is <postcode>. Is there anything else I can help you with today?	

表 3.2　DAMD 模型的错误生成实例展示

尽管 DAMD 模型在多领域对话建模任务上展现出了超越现有模型的性能表现，我们的模型仍然会几种类型的错误，如表3.2所示。在对话动作解码时，我们列出了模型预测出的五个概率最大的系统对话动作，对所有解码结果中都没有包含标准系统对话动作的错误示例进行了展示。左侧示例中，模型预测错了应该询问用户的语义槽名称，在用户表达了想要购买火车票后，应该优先确定日期，而不是直接确定出发、到达时间。右侧示例中，系统在未能收集到足够的信息（例如订餐人数）时，就向用户提供了餐厅的预订结果，不符合订餐流程。这些错误表明，不同任务中各语义槽的优先级、必要性等常识性逻辑规则，模型很难通过对话数据捕捉到，需要引入更多的常识性先验知识，可以作为未来的改进方向。表3.2底部的示例展示了一个在系统回复生成时出现的错误，模型虽然预测到了正确的系统对话动作，但在生成自然语言时遗漏了餐厅的地址。这个错误表明现有 Seq2Seq 模型的长序列建模能力仍然有提升空间，未来可以将 RNN 替换为 Transfomer 等更表达能力更强的模型，进一步提升根据对话动作序列生成自然语言序列这一条件分布的建模能力。

3.3　基于 DAMD 模型的多元化策略学习

DAMD 模型能够通过隐状态解码出人可以理解的对话状态和系统对话动作，大大增强了端到端对话模型的可解释性。特别是通过加入系统对话动作的解码，DAMD 模型具备了进行系统对话策略研究的可能，相比于先前对话策略隐含在自然语言生成的模型[33-34]，DAMD 可以通过控制系统的对话策略，进而控制生成的

回复，模型的可控性大大提高。接下来，我们将会介绍如何利用 DAMD 模型的这些特性，解决对话建模中普遍存在的，同一语境下可存在多种不同合理回复的“一对多”问题，展示如何在端到端对话系统中进行多元化对话策略学习以及生成多种不同的合理回复。

3.3.1　任务型对话中的一对多问题

高度的多样性与灵活性是人类对话所具有的典型特征，针对同一语境，可以存在多种合理但不同的回复方式。系统在进行对话建模时，必须考虑到这种多样性，以更好地处理多样化的用户行为。这个问题被称为对话中的“一对多”问题，在自由度更高、需要多样化的回复语言以吸引用户的闲聊系统中受到研究者的广泛关注[80,87-88]。由于在任务型对话系统中更重要的是学习能够顺利完成任务的对话策略，语言层面的多样性建模意义不大，“一对多”问题在任务型对话中的研究不多。但是，“一对多”问题在任务型对话中也是普遍存在的。且与语言层面的多

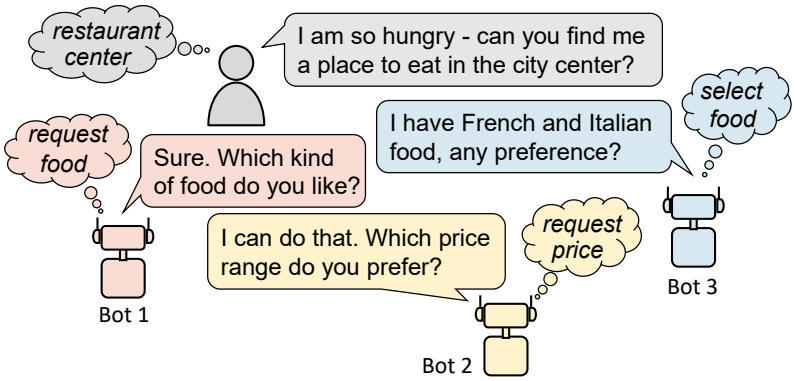

图 3.3　任务型对话中的“一对多”现象

样性不同，任务型对话中的“一对多”表现为系统对话策略上的多样性，即针对相似的用户需求（对话状态），系统可以选择多种合理但不同的对话动作进行回应，如图3.3所示。由于在训练对话模型时所使用的对话数据，一般只提供语境下的一个标准回复，因此每个对话状态的可行系统动作的分布取决于它们在数据集中的出现频率。我们统计了 MultiWOZ 数据集中，同一对话状态（相同领域、相同的语义槽值填充情况）下可能出现的不同系统动作，发现对于某些对话状态系统可采取多达 20 种回复方式（图3.4(a)），且这些回复方式的出现频率分布极为不平衡（图3.4(b)）。换言之，语言的灵活性导致可能有很多种对话策略都可以通向成功完成任务的最终目标，但在收集对话数据时，由于客服人员的习惯不同，可能有一些对话策略更容易被采用，被大量收集在数据集中，而其他对话策略则出现较少。在这种不平衡的对话数据集上训练的模型，会倾向于学习到最常见的对话策略，而

忽略了很少发生、但切实可行的系统行为，从而导致学习到的对话策略覆盖率低、鲁棒性差，不利于应对更加多样的用户表达。

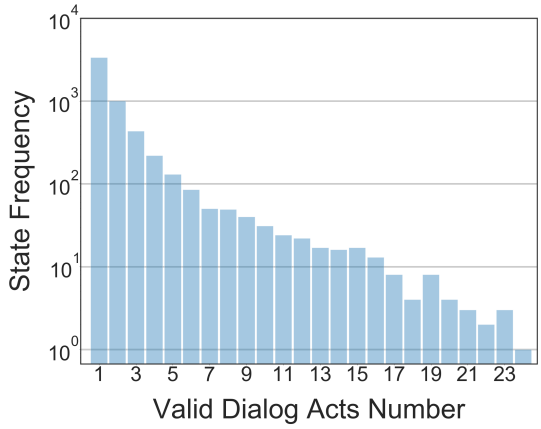

(a) “一对多”现象的普遍性

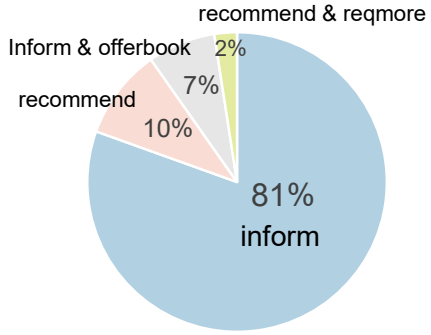

(b) 可行动作的分布不平衡

图 3.4　同一对话状态可对应多种合理的系统对话动作

我们的目标是通过数据增强的方式解决上述数据不平衡问题，通过学习同一对话状态的多个可行系统动作，以丰富系统对话策略的多样性，从而构建具备多元化系统回复方式的对话系统。

3.3.2　多动作数据增强方法

我们提出了多动作数据增强（Multi-Action Data Augmentation，MADA）方法框架，通过学习多元化的对话策略来增加系统回复语句生成的多样性。MADA 框架可适用于所有显式建模了对话状态和系统对话动作的任务型对话系统中对话策略的学习，而在我们的 DAMD 模型中，由于采用了单词序列形式的系统对话动作表示，利用 Seq2Seq 学习中的多元化解码方法[89-91]，可以更容易发挥 MADA 的优势学习到更加有效的多元化对话策略。

多动作数据增强的原理由图3.5所示。在学习包含一对多映射的对话策略之前，我们首先需要设计一种可更好地表征对话语境的广义对话状态，需要包含足够的信息，从而让对话系统可以决定下一步应该采取的动作。我们将第 t 轮对话的广义对话状态 S_t 定义为包括以下四类信息：

$$S_t \triangleq \langle D_t, B_t, DB_t, A_t^U \rangle \tag{3-9}$$

其中 D_t, B_t, DB_t, A_t^U 分别表示当前对话领域、使用语义槽值表示的对话状态、数据库搜索结果和当前轮的用户动作。其中，前三者是确定多领域任务型对话完成程度所必须的信息，而当前的用户动作对后续系统动作的影响在于有时系统需要

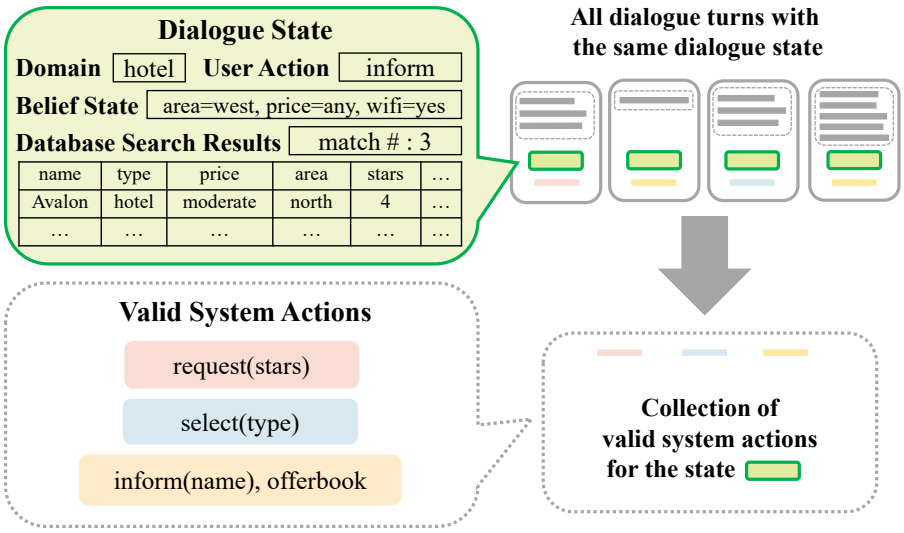

图 3.5　多动作数据增强方法原理

直接回应用户的需求，例如在用户询问电话时提供某实体的电话号码。

系统对话策略的学习可以看作最大化以下条件似然函数：

$$\mathcal{L} = \sum_{t \in \mathcal{D}} \log P(A_t | S_t) \tag{3-10}$$

其中 $\mathcal{D}$ 代表训练使用的对话数据集，A_t 是系统对话动作。由于“一对多”现象的存在，对于某一个广义对话状态 S，数据集中可能存在 K 个不同的系统动作 $A^{(1)}, \cdots, A^{(K)}$，可以作为对状态 S 的合理回应，即对于 $i = 1, \cdots, K$，$\exists t \in \mathcal{D}\ s.t.\ (S_t, A_t) = (S, A^{(i)})$，称为状态 S 下的可行系统动作，其集合记为 $\mathcal{V}(S)$。如果有一些状态-动作对 $(S, A^{(j)})$ 在数据集中出现的频率远低于其他状态-动作对 $(S, A^{(k)})$，则模型在训练时就会倾向于只学习到了经常出现的 S 到 $A^{(j)}$ 的映射，而忽略了那些不常出现的可行系统动作，学习到的对话策略缺乏多样性。这也是使用最大似然准则，在不平衡数据集上训练模型时的一个普遍问题[92]。

在 MADA 中，我们希望利用基于过采样的数据增强方式，将每一个广义对话状态 S_t 下的可行系统动作分布，转化为平衡分布。具体做法是，我们先遍历整个对话数据集，找到每一个广义对话状态 S_t 所有的可行系统对话动作 $\mathcal{V}(S)$，然后在使用每一组状态-动作对数据 (S_t, A_t) 时，从 $\mathcal{V}(S)$ 中采样额外的 $A_{t'}, t' \neq t$，组成一个可行系统动作的平衡分布，从而始终在平衡数据分布下训练策略模型。经过数据增强，新的目标函数为：

$$\mathcal{L}_{aug} = \sum_{t \in D} \sum_{A_{t'} \in \mathcal{V}^*(S_t)} \log P(A_{t'} | S_t) \tag{3-11}$$

其中 $\mathcal{V}^*(S_t) \subseteq \mathcal{V}(S_t)$ 是状态 S_t 下可行系统动作集合 $\mathcal{V}(S_t)$ 的一个子集。若直接取

$\mathcal{V}^*(S_t) = \mathcal{V}(S_t)$，则优化 $P(A|S_t)$ 的状态-动作对就恰好是 S_t 和其每一个可行系统动作组成的平衡数据。由于上述结论对于每一个 S_t 适用，因此可以推广到整个对话策略条件分布 $P(A|S)$ 的学习。

MADA 本质上是采用了过采样训练数据的方式，以处理数据不平衡问题。我们选择过采样而不是欠采样的原因，是为了确保对话框模型可以从所有可用的对话数据中学习。在实际应用时，我们可以选择不同的 $\mathcal{V}^*(S_t)$ 以实现不同粒度的对话动作多样性。我们发现对于某些系统对话动作，例如“推荐”，除了以“酒店名称”语义槽组为动作的参数之外，通常还会将其他语义槽“价格”、“星级”、“能否停车”、“是否有 wifi”等的排列组合，作为附加信息一起提供给用户，这使得“推荐”动作的数量成倍增加。这些动作的本质都是在进行某个酒店的推荐，只不过最终呈现给用户时所提供的信息略有不同，为了避免对这些语义相近的对话动作的过度采样，我们将具有相同对话动作类型的可行系统动作归为一组，从每个组中均匀采样以形成 $\mathcal{V}^*(S_t)$。这样一来，系统能学习到动作类型级别的多元化策略，例如直接进行“推荐”或者“询问”用户的更多要求，避免只学习到语义槽级别的策略多样性。

作为一种通用的多元化对话策略学习框架，MADA 适用于任何显式建模了对话状态和系统动作的任务型对话系统训练。然而，在一般的对话策略模型中，系统动作预测一般被处理为一个多分类问题，需要对每一个由“领域-动作总类-语义槽”构成的原子对话动作，判断其出现在当前系统对话动作中的概率，若概率超过某一阈值则加入当前系统对话动作中。例如，若要正确预测出系统动作“餐厅-询问（价格，食物种类）”，需要对原子动作“餐厅-询问-价格”和“餐厅-询问-食物种类”的预测概率超过阈值，其他原子动作的预测概率低于阈值。在这种方式下，系统对话动作的分布等于各个原子动作二元分布的联乘积，难以对通过 MADA 学习到的多元对话策略采样得到不同的系统对话动作。而在 DAMD 模型中，由于系统对话动作的预测被转化为一个序列解码问题，通过对序列每一个时刻的生成分布采样，即可得到不同的系统对话动作。同时，解码时也可以利用 diverse beam search[89]，top-k 采样[90]、top-p 采样[91] 等提高序列生成多样性的技巧，解码得到更加多样化的系统对话动作。在对 DAMD 模型进行数据增强时，我们仍然可以进行端到端的训练，只需要按照 MADA 的流程增强系统动作数据，而不用改变对话状态、自然语言回复等数据的使用。在生成多个系统回复时，只要解码得到多个系统对话动作后，再使用每个动作分别进行后续的系统回复生成，即可得到包含策略多样性的系统回复语句。

3.3.3　实验结果与分析

为了评估使用 MADA 进行多元化对话策略学习的效果，我们基于 MultiWOZ 上进行了多动作解码实验，并对后续生成的多样性系统回复进行了人工评测。除了对 DAMD 模型应用数据增强前后进行对比之外，我们还和当前的 MultiWOZ 上效果最好的模型 HDSA 进行了对比。HDSA 的系统对话动作预测采用的是上一节中介绍的多分类方法，在需要生成多个系统对话动作时，我们对原子动作的二元分类阈值进行采样，从而得到不同的动作组合，作为系统对话动作的采样结果。

模型及动作解码方式	动作种数		语义槽种数	
	无增强	增强后	无增强	增强后
解码单一系统动作解码				
DAMD + greedy	**1.00**	**1.00**	1.95	**2.51**
HDSA + fixed threshold	**1.00**	**1.00**	2.07	**2.40**
解码 5 个系统对话动作				
DAMD + beam search	2.67	**2.87**	3.36	**4.39**
DAMD + diverse beam search	2.68	**2.88**	3.41	**4.50**
DAMD + top-k sampling	3.08	**3.43**	3.61	**4.91**
DAMD + top-p sampling	3.08	**3.40**	3.79	**5.20**
HDSA + sampled threshold	1.32	**1.50**	3.08	**3.31**
解码 10 个系统对话动作				
DAMD + beam search	3.06	**3.39**	4.06	**5.29**
DAMD + diverse beam search	3.05	**3.39**	4.05	**5.31**
DAMD + top-k sampling	3.59	**4.12**	4.21	**5.77**
DAMD + top-p sampling	3.53	**4.02**	4.41	**6.17**
HDSA + sampled threshold	1.54	**1.83**	3.42	**3.92**

表 3.3　多对话动作解码结果

多动作解码实验结果如表3.3所示。我们为每一个对话状态解码 5 个或 10 个对话动作，统计解码出的所有对话动作中所包含的不同动作种类的数目，以及包含不同语义槽种类的数目，作为系统对话动作的多样性评价指标。从表中结果可以看出，在应用 MADA 进行数据增强后，所有模型、在使用各种解码方法的情况下，都取得了系统对话动作多样性的提升。通过 DAMD 和 HDSA 的对比可以看出，DAMD 模型所采用的单词序列形式系统对话动作，在建模多元化对话策略方面具有很大优势，且在进行数据增强后的多样性提升更为明显。在我们使用的 4 种不同解码方式的对比中，top-k 采样取得了最高的动作多样性，在解码 5 个系统对话动作时，模型配合数据增强生成了高达 3.43 种动作，再次体现了任务型对话中对话策略的高度多元性。

由于多动作解码实验是基于数据集的自动评估，可以计算解码出的系统对话

动作的多样性，但对于每个动作的合理性则很难判断，我们使用解码出的 5 个对话动作在端到端模型中生成的 5 句系统回复，进行了人工评测。我们对正常训练的 DAMD 模型、进行了数据增强训练的 DAMD（+）和进行了数据增强训练的 HDSA（+）这三种模型进行了对比。我们从 MultiWOZ 测试集中采样出 100 轮对话，对每一轮对话，分别使用这三个模型生成回复，每个模型生成 5 句，共计 15 句，雇佣志愿者进行了打分。在打分时，志愿者需要对每个模型生成的每一句话打一个 1-3 的合理度分数，分别代表该回复不合理、尚可或优秀。对每个模型生成的 5 句回复，志愿者还要统一打一个 1-5 的多样性得分，分值代表 5 句回复中所包含明显不同的对话策略数目。为了尽量消除不同志愿者偏好不同带来的随机性，每轮对话需要至少由 3 名志愿者进行打分。

模型	多样性	合理性	优秀%	尚可%	不合理%
DAMD	3.12	2.50	56.5%	**37.4%**	6.1%
DAMD (+)	**3.65**	**2.53**	**63.0**%	27.1%	9.9%
HDSA (+)	2.14	2.47	57.5%	32.5%	**10.0%**

表 3.4　多回复生成的人工评测结果

评测结果见表3.4。其中，多样性和合理性得分为每个模型所生成的 500 句回复的平均值，优秀、尚可和不合理的百分比分别为各个模型中取得相应合理性分数的回复所占比例。从结果可以看出，经过数据增强后，DAMD（+）在生成回复的多样性上获得了显著提高，并且还获得了最佳的平均合理性得分。由于多样性更大，DAMD（+）更有可能产生质量更高的系统回复语句。但另一方面，不合理回复的百分比也略有增加，表明我们学习到的多元化对话策略中还包含了一些不合理的对话策略，这可能是由于 MultiWOZ 数据集中对话状态和系统动作的标注错误所引入的数据噪声所致。此外，我们的 DAMD 模型生成的系统回复语句在多样性和合理性评分方面均优于 HDSA，这主要是因为我们的模型采用了更加合理的系统对话动作建模方式。

总之，总体结果表明我们提出的多动作数据增强框架可以有效提高对话系统的多元化对话策略学习能力，进而提高端到端对话系统生成多样化系统回复的能力，为建模任务型对话中的策略级“一对多”问题提供了一种有效的解决方案。学习多元化对话策略的意义在于，在使用强化学习等需要进行系统对话动作空间探索的方法时，可以获得更加高效的探索效率。另一方面，多元化的系统对话策略可以反过来促进用户模型的训练，得到表现更加全面、多样的用户模型。

第 4 章　基于状态空间模型框架的离散状态对话模型

尽管基于 Sequicity 框架的端到端对话模型取得了很好的实验效果，现有工作缺少从概率建模角度对这些模型的理论分析。在本章中，我们以 Sequicity 模型为例，通过分析其内部结构，给出了这一类端到端对话模型的概率图模型结构。进一步，我们针对 Sequicity 框架在概率建模方面存在的问题，提出了一种新的基于状态空间模型的对话模型框架，在理论上避免了 Sequicity 框架的现有问题。最后，我们在新对话模型框架下，结合 Seq2Seq 学习方法，提出了离散状态端到端对话模型 DSNet（Discrete-State Network），作为新框架下的具体模型实现。

4.1　基于 Sequicity 框架的端到端对话模型的概率建模分析

Sequicity 的基本原理已经在2.2.3中进行了介绍。根据公式2-21到2-26，我们可以画出 Sequicity 的模型结构图：

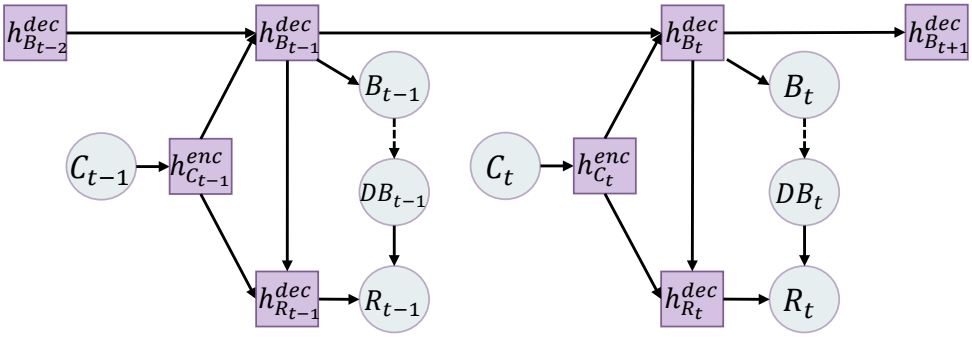

图 4.1　Sequicity 模型结构图

其中青色圆形结点表示自然语言形式的离散随机变量，包括轮次 t 的输入上下文 $\boldsymbol{C}_t$（其中 $\boldsymbol{C}_t = \{\boldsymbol{R}_{t-1}, \boldsymbol{U}_t\}, \boldsymbol{C}_1 = \boldsymbol{U}_1$）、对话状态 $\boldsymbol{B}_t$、数据库查询结果 $\boldsymbol{DB}_t$ 和系统回复语句 $\boldsymbol{R}_t$。紫色方形节点表示向量形式的连续随机变量，包括编码器的隐状态 h^{enc} 和解码器隐状态 h^{dec} 两类。图中的实线箭头表示模型中各随机变量之间的依赖关系，由于从对话状态 $\boldsymbol{B}_t$ 查询数据库得到 $\boldsymbol{DB}_t$ 的操作是在模型外完成的，使用虚线表示。

从图4.1中各随机变量之间的连接关系可以看出，Sequicity 中的信息是通过隐状态随机变量的计算流进行传递的。这种信息传递主要包括两方面：一是对话状态解码器隐状态 $h^{dec}_{B_t}$ 在各个对话轮次之间的信息传递，以实现对话状态跟踪；二是每一轮的对话状态解码器隐状态 $h^{dec}_{B_t}$ 到系统回复解码器隐状态 $h^{dec}_{R_t}$ 之间的信息传

递，以在生成回复时考虑整个对话的历史信息。在这种模型结构下，$\boldsymbol{B}_t$ 的解码依赖于隐状态变量 $h_{B_t}^{dec}$，即条件依赖于第 1 到第 t 轮的输入上下文 $\boldsymbol{C}_{1:t} \triangleq \boldsymbol{C}_1, \boldsymbol{C}_2, ..., \boldsymbol{C}_t$，因为 $h_{B_t}^{dec}$ 是由 $\boldsymbol{C}_{1:t}$ 通过 Seq2Seq 建模得到的各隐状态变量所共同决定的。同理，$\boldsymbol{R}_t$ 的解码也条件依赖于第 1 到第 t 轮的输入上下文 $\boldsymbol{C}_{1:t}$ 和数据库的解码结果 $\boldsymbol{DB}_t$。于是我们可以将 Sequicity 框架下的对话系统中各随机变量之间的概率关系，用如下概率图模型表示：

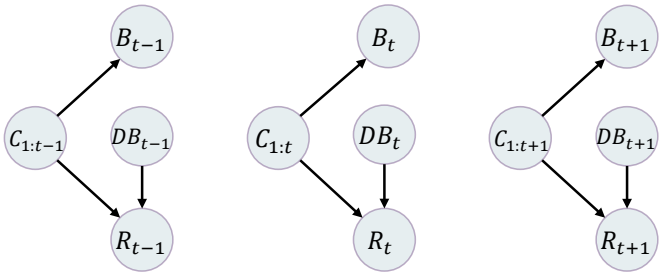

图 4.2　Sequicity 框架下对话系统的概率图模型

接下来，我们将基于图4.2，说明 Sequicity 这种概率建模方式存在的两个问题。

第一，对话状态 $\boldsymbol{B}_t$ 的解码依赖于完整的对话历史 $\boldsymbol{C}_{1:t}$，背离了 Sequicity 原本使用局部上下文 $\boldsymbol{C}_t$ 和上一轮对话状态 $\boldsymbol{B}_{t-1}$ 决定当前对话状态的初衷。使用对话状态这一紧凑表示方法建模任务型对话的历史信息，可以摒弃不重要的语言层面信息，只保留与对话任务目标相关的信息，在任务型对话建模中具有重要意义。在 Sequicity 论文中[33]，作者也将其框架阐述为生成 $\boldsymbol{B}_t$ 只需要参考 $\boldsymbol{B}_{t-1}$ 和 $\boldsymbol{C}_t$，而不用参考完整对话历史，并分析了这种使用紧凑对话状态表达对话历史带来的优势。然而，通过对实际模型结构的分析可以发现，这一马尔可夫假设并不成立，解码某一轮的对话状态 $\boldsymbol{B}_t$ 时，仍然需要访问完整的对话历史，而 $\boldsymbol{B}_{t-1}$ 到 $\boldsymbol{B}_t$ 的转移概率并没有被建模。事实上，Sequicity 的对话状态跟踪是通过隐状态各对话轮次之间 $h_{B_t}^{dec}$ 的连接实现的。这种连接方式虽然也可以处理各个对话状态之间的信息传递，但由于隐状态向量没有明确定义的概率分布，隐状态之间的转移难以观测，难以解释模型的对话状态转移行为。

第二，Sequicity 只建模了条件概率 $P(\boldsymbol{B}_t|\boldsymbol{C}_{1:t})$ 和 $P(\boldsymbol{R}_t|\boldsymbol{C}_{1:t})$，而没有建模 $\boldsymbol{R}_t$ 与 $\boldsymbol{B}_t$ 之间的条件依赖关系。和上面的分析类似，Sequicity 是通过隐状态 $h_{B_t}^{dec}$ 与 $h_{R_t}^{dec}$ 之间的连接，进行对话状态到系统回复之间的信息传递。在这种建模方式下，只能通过分别提供 $\boldsymbol{B}_t$ 和 $\boldsymbol{R}_t$ 的有标注数据，用有监督学习的方式分别进行条件概率 $P(\boldsymbol{B}_t|\boldsymbol{C}_{1:t})$ 和 $P(\boldsymbol{R}_t|\boldsymbol{C}_{1:t})$ 的学习。在对话数据量较大时，对每一轮对话进行对话状态 $\boldsymbol{B}_t$ 的标注会产生极大的开销，这是限制 Sequicity 模型实际应用价值的一个重要

问题。

上述问题在所有基于 Sequicity 框架的模型（FSDM[34]、MOSS[35]、DAMD 3.1）中普遍存在。此外，在增加了系统对话动作等其他系统中间状态的解码器时，其建模方式也和上面分析过的 B_t、R_t 类似。以系统对话动作 A_t 为例，加入 A_t 的解码器后，对话模型中增加了 $P(A_t|C_{1:t})$ 的建模，仍然需要提供 A_t 的标注数据才能对该条件概率进行优化。针对目前 Sequicity 框架存在的这些局限性，我们提出了一种新的基于状态空间模型的对话模型框架，有效避免了现有问题。

4.2　基于状态空间模型的对话模型框架

状态空间模型[93-94]（State Space Model，SSM）是一类描述隐变量（Latent Variable）和可观测变量（Observed Variable）之间概率依赖性的概率图形模型。状态空间模型为输出是一个可观测随机过程、而内部状态未知的时序动态系统，提供了一般性的分析方法，在神经科学、信号处理等序列数据的建模与分析中起着至关重要的作用。对话建模是一个典型的序列数据建模任务，且当系统中间状态（对话状态、系统对话动作等）无标注时，即可视为模型隐变量，恰好符合状态空间模型的建模情景。因此，我们提出使用使用状态空间模型作为对话建模的基本框架。

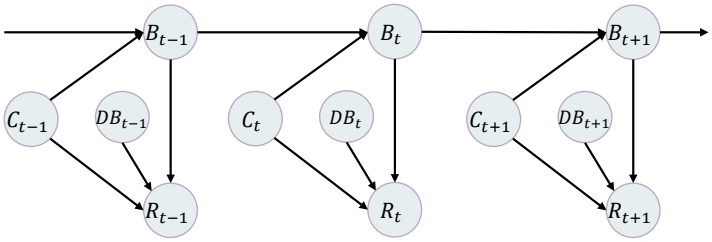

图 4.3　SSM 框架下对话模型的概率图模型

图4.3给出了新框架下的一种对话系统概率图模型，包括任务型对话系统的两个基本要素——对话状态 B_t 和回复语句 R_t 的建模。该模型与图4.2所示 Sequicity 概率图模型有两点区别。第一，加入了各轮次对话状态的转移概率建模 $B_{t-1} \rightarrow B_t \rightarrow B_{t+1}$，即状态空间模型中的状态转移概率。第二，加入了给定对话状态 B_t 时系统动作 R_t 的条件概率 $P(R_t|B_t)$ 的建模，即状态空间模型中的发射概率。由此，对话状态和对话动作联合建模成了一个生成模型，我们可以写出在一个 T 轮的对话中，它们的联合分布：

$$P(B_{1:T}, R_{1:T}|U_{1:T}) = \prod_t P(B_t|B_{t-1}, C_t)P(R_t|B_t, DB_t, C_t) \tag{4-1}$$

进行以上生成式建模的好处在于，通过建模条件概率 $P(R_t|B_t)$ 明确了 R_t 与 B_t 之间的依赖关系，在 B_t 未知时即可根据 R_t 中包含的信息，对隐变量 B_t 进行推断，即使用贝叶斯公式计算后验概率：

$$\begin{aligned} P(B_{1:T}|R_{1:T},U_{1:T}) &= \frac{P(B_{1:T},R_{1:T}|U_{1:T})}{P(R_{1:T}|U_{1:T})} \\ &= \frac{1}{Z}\prod_t P(B_t|B_{t-1},C_t)P(R_t|B_t,DB_t,C_t) \end{aligned} \tag{4-2}$$

其中 Z 表示归一化常数。

从回复语句 R_t 中推断对话状态 B_t 时，需要最大化后验概率 $P(B_t|R_t,U_{1:t})$，直观来看即找到用户语句中那些最可能导致了系统生成 R_t 的“关键”词。这种推断方式的可行性可以从以下两方面解释。其一，由于系统经常重复用户的需求，即语义槽值，很多系统回复中都会直接包括对话状态的信息。例如用户说“我想找一个便宜的快餐店”时，一种较为普遍的系统回复是“数据库中找到 x 个便宜的快餐店，请问您对位置有要求吗”，“便宜”、“快餐”等语义槽信息作为同时出现在用户语句和系统回复中的关键词，很容易被隐变量所捕捉到，即学习到了正确的对话状态。另一方面，若系统已经基于有标注数据进行一些有监督学习，或在第一种较为容易学习的情况下，学习到了一些正确的对话状态表示，则结合 Seq2Seq 模型的语义建模能力，系统可能可以掌握到一些标准句式，例如“我想要 XXX 的……”，无论“XXX”是否在回复语句 R_t 中出现，都会被提取为对话状态中的语义槽值。

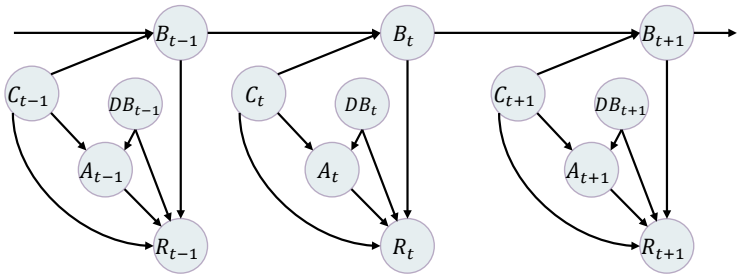

图 4.4　加入对话动作建模的概率图模型

此外，状态空间模型具有很高的灵活性，可以十分方便地加入更多系统中间状态的建模。图4.4中展示了加入对话动作建模后，对话模型的概率图模型结构。需要说明的一点是，由于我们使用的系统对话动作是由当前对话领域、动作种类和语义槽名称三部分组成的，对话状态中的各语义槽具体取值不会影响系统对话动作的预测。对话状态对系统对话动作的唯一影响在于，当系统需要对用户进行询

问，让用户提供更多信息时，应该避免询问那些已经在对话状态中得到填充的语义槽。因此，我们根据对话状态中各个语义槽是否已经被用户提到，形成一个指示向量，用于指导系统对话动作的预测。由于使用 $\boldsymbol{B}_t$ 生成该指示向量的过程是一个类似数据库查询的确定性过程，我们将该指示向量吸收到 $\boldsymbol{DB}_t$ 中，从而不再图中增加额外的变量。加入系统动作建模后模型的联合分布及后验概率为：

$$P(B_{1:T}, A_{1:T}, R_{1:T}|U_{1:T}) = \prod_t P(B_t|B_{t-1}, C_t)P(A_t|DB_t, C_t)P(R_t|B_t, DB_t, A_t, C_t) \tag{4-3}$$

$$P(B_{1:T}, A_{1:T}|R_{1:T}, U_{1:T}) = P(B_{1:T}|R_{1:T}, U_{1:T})\prod_t P(A_t|R_t, C_t) \tag{4-4}$$

上述两种对话模型框架，均为一般性的任务型对话建模框架，适用于各种具体的模型实现。在下一节中，我们将介绍一种沿用了现有结合拷贝机制的 Seq2Seq 学习架构的实现方式，在改进了概率建模方式的同时，保留了现有端到端对话模型的优点。

4.3　离散状态端到端对话模型 DSNet

在新框架下进行端到端对话模型设计时，我们仍然沿用了现有端到端对话型采用的 Seq2Seq 学习架构，采用结合拷贝机制的编解码器结构进行对话系统中各中间状态及系统回复语句的序列学习。不同于之前模型内部均为连续状态（隐状态向量）的端到端对话模型，在新框架下，我们需要将对话状态 $\boldsymbol{B}_t$ 等离散随机变量引入端到端系统内部，形成离散状态（Discrete State）。由此得到的新对话模型，我们称之为离散状态端到端对话模型 DSNet（Discrete-State Network）。

4.3.1　模型整体结构

本节将对基本的 DSNet 模型以及额外加入了系统对话动作建模的 DSNet-A 模型（分别对应4.2节中的两种概率图模型）的结构及原理进行介绍。

图4.5给出了 DSNet 的基本模型结构。其中 DataBase 表示数据库，用于使用对话状态 $\boldsymbol{B}_t$ 查询得到 $\boldsymbol{DB}_t$，控制系统回复生成，图中省略了 DataBase 到查询结果 $\boldsymbol{DB}_t$ 的依赖关系。DSNet 和图4.1中展示的 Sequicity 模型结构的最大区别在于，在得到每一轮的对话状态隐状态 $h_{B_t}^{dec}$ 后，不直接使用 $h_{B_t}^{dec}$ 计算系统回复解码器的隐状态 $h_{R_t}^{dec}$ 和下一轮的对话状态隐状态 $h_{B_{t+1}}^{dec}$，而是用 $h_{B_t}^{dec}$ 解码得到 $\boldsymbol{B}_t$ 后，再重新

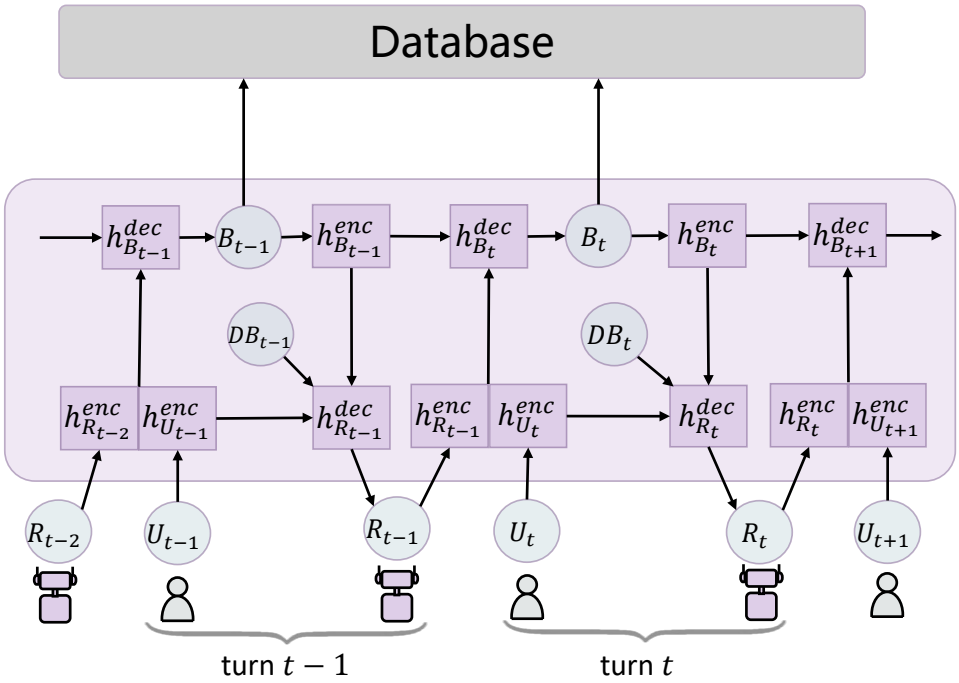

图 4.5　DSNet 模型结构

送入一个新引入的对话状态编码器，用编码器隐状态 $h^{enc}_{B_t}$ 进行后续隐状态的计算。这样一来，系统回复语句 $\boldsymbol{R}_t$ 以及后续的对话状态 $\boldsymbol{B}_{t+1}$ 都直接依赖于当前对话状态的解码结果 $\boldsymbol{B}_t$，从而符合图4.3中描述的概率图模型结构。在使用 $\boldsymbol{B}_t$ 时，我们仍然采用 Seq2Seq 的建模方式，即先将其编码为隐状态后，再送入解码器解码句 $\boldsymbol{R}_t$ 和 $\boldsymbol{B}_{t+1}$。由于 $h^{enc}_{B_t}$ 和 $h^{dec}_{B_t}$ 均为 $\boldsymbol{B}_t$ 序列经过编、解码器处理后得到的向量空间表达，其分布较为接近，模型后续的计算流程可以直接沿用 Sequicity 的结构和超参数设定，不需要全部重新调试。模型的计算流程可以用如下公式表示：

$$h^{enc}_{C_t} = \mathbf{Encoder}_C(R_{t-1}, U_t) \tag{4-5}$$

$$h^{enc}_{B_{t-1}} = \mathbf{Encoder}_B(B_{t-1}) \tag{4-6}$$

$$h^{dec}_{B_t} = \mathbf{Decoder}_B(h^{enc}_{C_t}, h^{enc}_{B_{t-1}}) \tag{4-7}$$

$$B_t = \mathrm{CopyDecode}(h^{dec}_{B_t}, h^{enc}_{C_t}, h^{enc}_{B_{t-1}}) \tag{4-8}$$

$$DB_t = \mathrm{DataBaseSearch}(B_t) \tag{4-9}$$

$$h^{enc}_{B_t} = \mathbf{Encoder}_B(B_t) \tag{4-10}$$

$$h^{dec}_{R_t} = \mathbf{Decoder}_R(h^{enc}_{C_t}, h^{enc}_{B_t}, DB_t) \tag{4-11}$$

$$R_t = \mathrm{CopyDecode}(h^{dec}_{R_t}, h^{enc}_{C_t}, h^{enc}_{B_t}) \tag{4-12}$$

其中 **Encoder** 和 **Decoder** 可使用任意编、解码器模型，不一定局限为 RNN。$CopyDecode(\cdot)$ 表示基于拷贝机制的单词序列解码过程，从公式中可以清晰看出各个词序列之间的单词拷贝流方向，即对话状态 $\boldsymbol{B}_t$ 从当前输入上下文 $\boldsymbol{C}_t$ 和上一轮对话状态中 $\boldsymbol{B}_{t-1}$ 中拷贝单词，系统回复语句从当前输入上下文 $\boldsymbol{C}_t$ 和更新后的对话状态 $\boldsymbol{B}_t$ 中拷贝单词，符合任务型对话的一般规律。

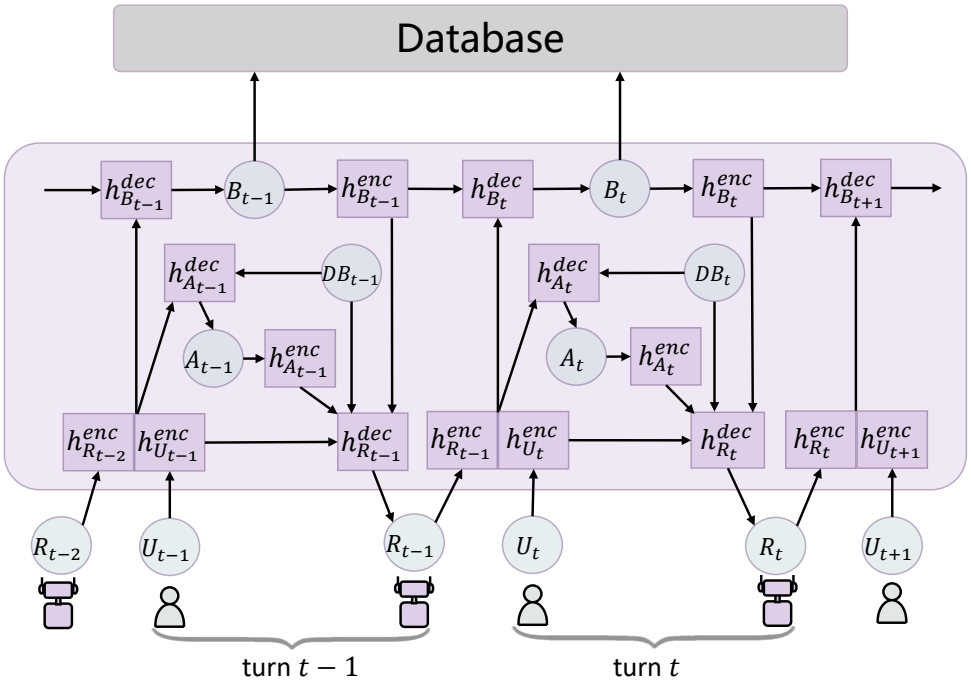

图 4.6　DSNet-A 模型结构

我们可以采用和上述相似的方式加入了系统对话动作建模，得到 DSNet-A 模型，其结构如图4.6所示。在 DSNet-A 中，系统对话动作 $\boldsymbol{A}_t$ 也作为离散变量进入了端到端系统内部，影响系统回复语句 $\boldsymbol{R}_t$ 的解码。模型中输入上下文的编码及对话状态的解码等和 DSNet 的公式4-5到4-8相同。而在 $\boldsymbol{B}_t$ 除了用于数据库搜索之外，还需要计算出一个语义槽填充情况的指示向量，详见4.2节中的讨论。之后，系统对话动作和系统回复语句的解码过程如下所示：

$$\boldsymbol{DB}_t = \text{DataBaseSearch}(\boldsymbol{B}_t) \oplus \text{FillingIndicator}(\boldsymbol{B}_t) \tag{4-13}$$

$$h^{dec}_{A_t} = \textbf{Decoder}_B(h^{enc}_{C_t}, h^{enc}_{B_t}, \boldsymbol{DB}_t) \tag{4-14}$$

$$\boldsymbol{A}_t = \text{Decode}(h^{dec}_{A_t}) \tag{4-15}$$

$$h^{enc}_{A_t} = \textbf{Encoder}_A(\boldsymbol{A}_t) \tag{4-16}$$

$$h_{R_t}^{dec} = \mathbf{Decoder}_R(h_{C_t}^{enc}, h_{B_t}^{enc}, DB_t, h_{A_t}^{enc}) \tag{4-17}$$

$$R_t = \text{CopyDecode}(h_{R_t}^{dec}, h_{C_t}^{enc}, h_{B_t}^{enc}) \tag{4-18}$$

其中 FillingIndicator 表示对话状态到语义槽填充情况指示向量的映射函数，$\oplus$ 表示向量拼接。注意到，在解码系统对话动作时，我们直接使用其解码器隐状态 $h_{A_t}^{dec}$ 进行解码，而不使用拷贝机制。这是因为系统对话动作作为一些特殊定义的标识符，不会出现在用户的输入上下文中，不存在拷贝的可能性。同理，在解码系统回复语句 $\boldsymbol{R}_t$ 时，仍然只从 $\boldsymbol{C}_t$ 和 $\boldsymbol{B}_t$ 中进行单词拷贝，$h_{A_t}^{enc}$ 仅用于计算 $\boldsymbol{R}_t$ 解码时的单词生成概率。在对话动作解码时是否使用拷贝机制需要视具体情况而定，例如在3.1节介绍的 DAMD 模型中，由于 $\boldsymbol{A}_t$ 和 $\boldsymbol{B}_t$ 存在一定的词重合可能，采用类似的系统对话动作设计时，就可以在解码时加入拷贝机制。

4.3.2　对话状态与系统对话动作的建模方式

在3.1节中，我们已经分析过 Sequicity 采用的对话状态表示存在的问题，并在 DAMD 模型中给出了加入领域标识符和语义槽标示符的解决方案。然而，模型只能通过从标注数据中进行有监督学习，才有可能学习到如何解码这些用于表示对话状态结构的标识符，在无对话状态标注时这种做法不可行。在 DSNet 中，我们通过将对话状态的结构化信息直接建模到对话状态解码器模型中，在解码时只进行各个语义槽取值的解码，从而使无监督学习可以发挥作用。

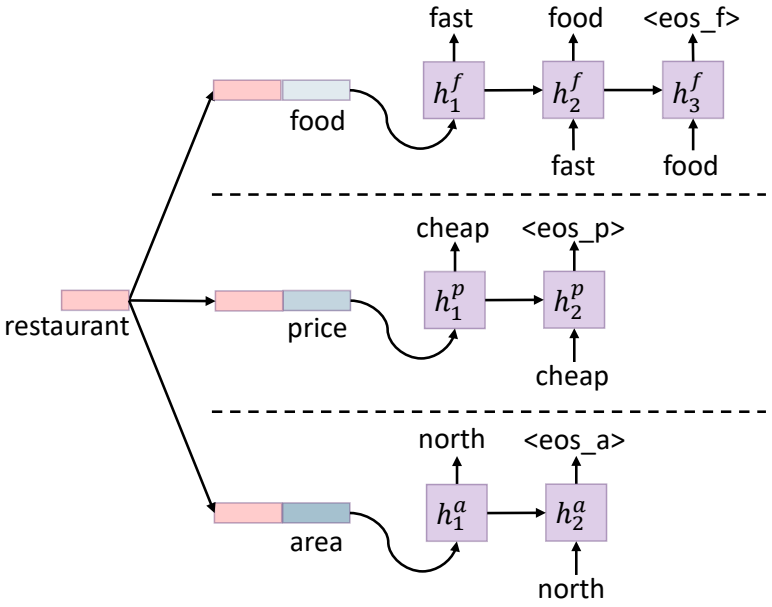

图 4.7　DSNet 的对话状态解码工作原理

在实现时，我们参考现有对话状态跟踪模型的相关研究[57]，将需要对话领域知识本体中所有的语义槽，依次输入到对话状态解码器中，进行各个语义槽取值的独立解码，如图4.7所示。其中，输入方式是将每个语义槽的领域名称词向量和槽名称词向量拼接后，作为对话状态解码器初始时刻的输入。<eos_f>、<eos_p>、<eos_a> 分别用于指示三个语义槽值解码过程的终止。在对语义槽进行取值解码时，使用的是同一个解码器模型，不同的只有初始时刻的输入。这种做法的好处是：（1）解码器只需要解码语义槽取值，即从用户输入或之前的对话状态中进行拷贝，而不需要额外学习对话的领域知识结构信息；（2）由于各个语义槽的取值应该相互独立，进行独立解码也比有时序依赖关系的顺序解码更符合逻辑；（3）可以实现不同领域、不同语义槽之间的信息共享，提高对话状态跟踪的性能。在得到各个语义槽的解码隐状态表示 h_{slot-i}^{dec} 后，将所有向量进行拼接，即可得到对话状态的隐状态表示 $h_{B_t}^{dec}$。

在 DSNet-A 中进行系统对话动作的解码时，我们也采用了相似的处理办法。依据之前的分析，沿用之前 DAMD 模型中使用的由领域标识符、动作标识符和语义槽名称组成的系统对话动作并不现实，为了更好地进行无监督学习，我们对系统对话动作进行了一定程度的简化。简化后的对话动作只包含任务型对话中最核心的“问”和“答”两种动作，沿用上面介绍的语义槽值独立解码的思路，在对话动作解码器中分别对这两种动作应该包含的内容进行解码。如图4.8所示，在用户询问系统一家餐厅的电话号码时，系统对话动作应该为提供电话号码的取值，即“答”动作的内容解码为电话号码取值的标识符“[phone]”，而系统在回答问题时不会向用户发问，“问”动作解码结果为空。在用户提出“想找一家便宜的餐厅”时，系统会进一步询问用户的需求，“问”动作的内容可解码为“price”、“area”等用户未提到的语义槽，而“答”动作则为空。

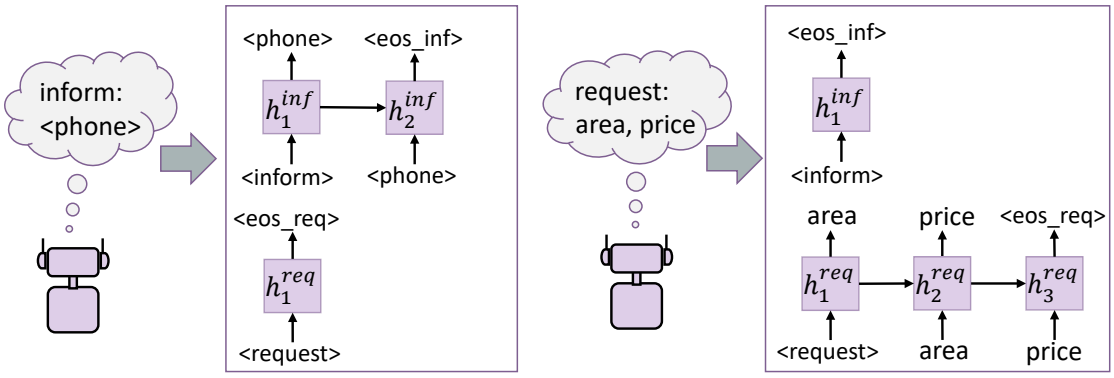

图 4.8　DSNet-A 的系统对话动作解码工作原理

4.4　DSNet 的无监督学习算法

设我们的对话模型为 p_θ，其中 θ 为模型中所有可学习的参数。对话建模的学习目标为，给定某个对话数据集 $\mathcal{D} = \{(U_{1:T}, R_{1:T})\}$，最大化整个对话数据集上给定用户输入 $U_{1:T}$ 后系统回复 $R_{1:T}$ 的条件概率 $p_\theta(R|U) = \prod_{\mathcal{D}} p_\theta(R_{1:T}|U_{1:T})$。由于难以直接对 $p_\theta(R|U)$ 求梯度进行优化，一般通过对相对容易计算导数的联合对数似然 $\log p_\theta(B_{1:T}, R_{1:T}|U)$ 求梯度，转而优化 $\log p_\theta(R|U)$。而估计 $\log p_\theta(B_{1:T}, R_{1:T}|U)$ 梯度的核心问题，是从模型后验分布 $p_\theta(B_{1:T}|R_{1:T}, U_{1:T})$ 中采样，即对隐状态——对话状态 $B_{1:T}$ 进行推断。

在推断对话状态 $B_{1:T}$ 时，我们虽然可以通过式4-2计算后验概率 $p_\theta(B_{1:T}|R_{1:T}, U_{1:T})$，但由于计算归一化常数 Z 需要计算完全似然在隐状态空间上的积分，无法得到闭式解，因此无法对这一后验概率进行精确计算。一种替代方法是，引入一个参数为 ϕ 的推断模型 q_ϕ，来对后验概率 $p_\theta(B_{1:T}|R_{1:T}, U_{1:T})$ 进行近似估计。在 DSNet 中，对第 t 轮对话状态的推断模型 $q_\phi(B_t|B_{t-1}, C_t, R_t)$ 如图4.9中的红色虚线所示。在具体实现时，$q_\phi(B_t|B_{t-1}, C_t, R_t)$ 网络和先验分布 $p_\theta(B_t|B_{t-1}, C_t)$ 网络采用类似 Seq2Seq 结构，只不过增加了 R_t 的编码器和对 R_t 中单词拷贝概率的计算，其他部分保持一致。

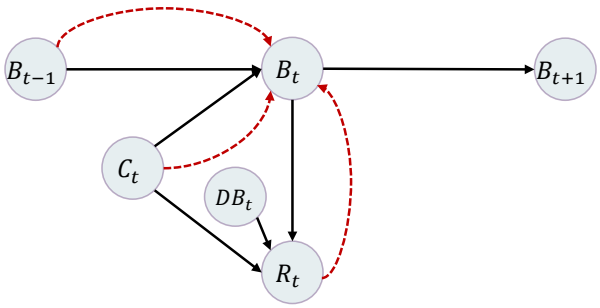

图 4.9　DSNet 的推断模型示意

我们希望推断模型的分布和模型的真实后验分布尽量接近，以得到更符合真实后验分布的隐变量（对话状态）样本，从而更好地估计 $\log p_\theta(B_{1:T}, R_{1:T}|U)$ 的梯度。在本节中，我们将介绍如何使用 VAE[36] 和 RWS[38] 这两种生成模型的推断算法解决上述问题。由于我们的 DSNet 对话模型是一种状态空间模型框架下的离散状态序列模型，我们将解释如何将这两种算法推广到对话建模的序列推断任务上，进而实现在无对话状态 B_t 标注时 DSNet 的无监督学习。虽然我们在讨论算法流程时以 DSNet 为例，但算法本身具有普适性，也可以应用于其他具有序列离散隐变量的推断任务。

4.4.1　序列模型的 SCVAE 算法

VAE（Variational Auto-Enconder）是一类包含隐变量和由隐变量生成的可观测变量的生成模型，其假设数据 x 由某些隐变量 $z \sim p(z)$ 通过条件分布 $p(x|z)$ 生成。在推断时，使用另一个分布 $q(z|x)$ 近似不可计算的真实后验分布 $p(z|x)$，$q(z|x)$ 和 $p(x|z)$ 分别相当于编码器和解码器，对数据进行压缩与重建，VAE 给出了这两个网络的参数优化方式[36]。若 x 和 z 是在某种条件 c 下生成的，即 $z \sim p(z|c), x \sim p(x|z,c)$，这种特定条件下的生成模型称为 CVAE[37]（Conditional VAE）模型。CVAE 通过优化下式定义的经验下界对生成模型和推断模型参数进行优化：

$$\tilde{\mathcal{L}}_{ELBO} = \mathbb{E}_{q(z|x,c)}[\log p(x|z,c)] - \mathrm{KL}[q(z|x,c) \| p(z|c)] \tag{4-19}$$

其中 $\mathrm{KL}[q\|p]$ 表示分布 q 和分布 p 的 KL 散度，用于衡量两个分布的相似度。可以证明 $\mathcal{L}_{ELBO}$ 是 $\log p(x|c)$ 的一个下界，因此优化 $\mathcal{L}_{ELBO}$ 的同时也会优化 $\log p(x|c)$。

本研究中，我们将 CVAE 推广到了任务型对话系统中的序列变量建模任务上，称为 SCVAE（Sequential CAE），即序列模型的 CVAE 算法。在进行对话建模时，隐变量 $\boldsymbol{B}_t$ 和可观测变量 $\boldsymbol{R}_t$ 都是基于当前的对话上下文 $\boldsymbol{C}_t$ 生成的，符合 CVAE 的模型假设，其经验下界为：

$$\mathcal{L}_{ELBO} = \sum_t \mathbb{E}_{q_\phi(\boldsymbol{B}_t|\boldsymbol{B}_{t-1},\boldsymbol{C}_t)}\left[\log p_\theta(\boldsymbol{R}_t|\boldsymbol{B}_t,\boldsymbol{C}_t)\right] - \mathrm{KL}\left[q_\phi(\boldsymbol{B}_t|\boldsymbol{B}_{t-1},\boldsymbol{C}_t,\boldsymbol{R}_t) \| p_\theta(\boldsymbol{B}_t|\boldsymbol{B}_{t-1},\boldsymbol{C}_t)\right] \tag{4-20}$$

序列建模的特点是，每一轮对话状态 $\boldsymbol{B}_t$ 的采样分布 $q_\phi(\boldsymbol{B}_t|\boldsymbol{B}_{t-1},\boldsymbol{C}_t,\boldsymbol{R}_t)$ 都需要依赖于上一轮的对话状态 $\boldsymbol{B}_{t-1}$。由于无监督学习时没有每一轮的真实对话状态，我们将每一轮从 q 中采出的一个对话状态样本，作为当前轮的对话状态，用于计算下一轮对话状态的采样分布。SCVAE 的算法流程如算法1所示。

如何计算 $\mathcal{L}_{ELBO}$ 对模型参数 θ 和 ϕ 的梯度，是应用 VAE 算法时的一个重要问题。尤其是当隐变量为离散变量时，由于离散状态空间不可导，我们无法直接计算 $\mathcal{L}_{ELBO}$ 对离散隐变量的导数。解决离散隐变量的梯度估计问题有值函数法[95-96]、Straight-Through（ST）法[97]、重参数法[98] 等三类主流方法。在我们的实验中，我们尝试了 ST、ST-Gumbel、Gumbel[98] 等几种梯度估计方法，选择实验效果最好的 ST 法，即使用离散隐变量正常进行前向计算，而使用其 softmax 函数输出的概率进行后向梯度计算。

Algorithm 1 SCVAE

Input: Data $\mathcal{D} = \{(U_{1:T_i}, R_{1:T_i})\}_{i=1}^{N_D}$, initialized θ, ϕ, sample number N.
for $D_i \in \mathcal{D}$ **do**
    Sample $B_1^k \sim q_\phi(B_1|U_1, R_1)$ for $k = 1, ..., N$
    for $t = 2, \cdots, T_i$ **do**
        Sample $B_t^k \sim q_\phi(B_t|B_{t-1}^k, R_{t-1}, U_t, R_t)$ for $k = 1, ..., N$
    end for
    $\mathcal{L}_{ELBO} = \sum_{t=1}^{T_i} \frac{1}{N} \sum_{k=1}^{N} q_\phi(B_t^k|B_{t-1}^k, R_{t-1}, U_t, R_t) \log \frac{p_\theta(R_t, B_t^k|B_{t-1}^k, R_{t-1}, U_t)}{q_\phi(B_t^k|B_{t-1}^k, R_{t-1}, U_t, R_t)}$
    $\theta = \theta + \nabla_\theta \mathcal{L}_{ELBO}$
    $\phi = \phi + \nabla_\phi \mathcal{L}_{ELBO}$
end for

4.4.2　序列模型的 SCRWS 算法

RWS（Reweighted Wake-Sleep）也是同时进行生成模型和推断网络学习的一种算法，其和 VAE 的主要区别在于 RWS 交替优化两个目标函数，以分别对生成模型和推断网络进行优化。与 CVAE 类似，我们依旧考虑给定条件 c 下的生成模型 $p_\theta(x, z|c)$。优化生成模型参数 θ 时，RWS 通过下式计算关于 θ 的梯度：

$$w_k = \frac{p_\theta(x, z_k|c)}{q_\phi(z_k|x, c)} \tag{4-21}$$

$$W_k = \frac{w_k}{\sum_{l=1}^{K} w_l} \tag{4-22}$$

$$\sum_{k=1}^{K} W_k \nabla_\theta \log p_\theta(x, z_k|c) \tag{4-23}$$

其中 $z_{1:K} \sim q_\phi(z|x, c)$ 表示 K 个后验样本。在学习推断模型 q_ϕ 时，RWS 通过优化真实后验概率 $p_\theta(z|x, c)$ 和采样分布 $q_\phi(z|x, c)$ 之间的负 KL 散度，进行参数 ϕ 的更新。其关于 ϕ 的梯度为：

$$\sum_{k=1}^{K} W_k \nabla_\phi \log q_\phi(z_k|x, c) \tag{4-24}$$

RWS 的主要思想是使用采样分布进行重要性采样作为 $\log p_\theta(x|c)$ 的估计。而在对话模型中进行序列采样时，第 t 轮的样本 B_t 会用于计算第 $t+1$ 轮的采样分布 $q_\phi(B_{t+1}|B_t, C_{t+1})$，从而形成一条隐变量样本轨迹 $B_{1:T}$，上述 RWS 中的 K 个样本即成为 K 条样本轨迹。而在序列采样中使用重要性采样的问题是，几轮之后所有重要性权重可能会集中到 1-2 个样本上，而其他样本的权重均接近 0，即发生了

样本的坍缩[99]。解决样本坍缩的方法是对样本进行重采样，即在每一轮采样 $\boldsymbol{B}_t^k$ 时，不直接使用 $\boldsymbol{B}_{t-1}^k$ 作为依赖，而是通过采样在 K 个样本中重新选择 $\boldsymbol{B}_{t-1}$。这种使用重采样的序列重要性采样算法称为 SMC[99]（Sequential Monte Carlo）。我们的 SCRWS 算法即为 CRWS 和 SMC 的结合，其流程如算法2所示。

Algorithm 2 SCRWS

1: **Input**: initialized model parameter θ, ϕ, particle number N, dialog data $\mathcal{D} = \{D_i\}_{i=1}^{N_D} = \{(U_{1:T_i}, R_{1:T_i})\}_{i=1}^{N_D}$.
2: **for** $D_i \in \mathcal{D}$ **do**
3: $\quad \{B_{1:T_i}^k\}_{k=1}^N, \{W_{1:T_i}^k\}_{k=1}^N, \hat{p}(R_{1:T_i}|U_{1:T_i}) = \mathbf{SMC}(\theta, \phi, N, (U_{1:T_i}, R_{1:T_i}))$
4: $\quad \theta = \theta + \sum_{t=1}^{T_i} \sum_{k=1}^N W_t^k \nabla_\theta \log p_\theta(R_t, B_t^k | B_{t-1}^{A_{t-1}^k}, R_{t-1}, U_t)$
5: $\quad \phi = \phi + \sum_{t=1}^{T_i} \sum_{k=1}^N W_t^k \nabla_\phi \log q_\phi(B_t^k | B_{t-1}^{A_{t-1}^k}, R_{t-1}, U_t, R_t)$
6: **end for**

其中，SMC 算法的具体实现见附录A。SCRWS 的算法和另一种结合 RWS 和 SMC 的算法 NASMC[39] 在原理上类似，其区别在于 SCRWS 中考虑的模型是特定条件下的生成模型，即比 NASMC 中的模型增加了条件依赖。

4.5　实验结果

为了对 DSNet 的性能进行评估，我们在 Camrest676 数据集上进行了实验，并与现有系统进行了比较。实验主要分为有监督实验和半监督实验两部分，前者体现了 DSNet 作为一种端到端任务型对话系统的性能水平，后者则展示了在减少对话状态、系统对话动作等标注数据的数量时，使用半监督学习对系统性能的提升能力。

4.5.1　Camrest676 数据集

Camrest676 数据集[11] 是剑桥对话研究组采用 WOZ 方式收集的餐厅领域的任务型对话数据集，即雇佣志愿者分别扮演用户和餐厅查找系统的角色，进行剑桥地区餐厅的查找与推荐。数据集使用的领域知识本体包含 3 个告知语义槽和 7 个问询语义槽，各语义槽的具体信息及相应的数据库示例见2.1.1节。在数据量方面，Camrest676 包含 676 个对话，共计 2700 个左右的对话轮次，是任务型对话系统评估最常用的数据集之一。在使用该数据集时，我们和其他研究工作保持一致，将数据按照 3：1：1 的比例分为训练集、开发集和验证集，使用训练集进行对话系统的训练，在开发集上进行超参数微调，最后使用测试集中的对话对系统进行评估。

在该数据集上，我们使用以下 4 个评价指标评估对话系统的性能：

- BLEU 得分：系统生成回复和数据集中的标准回复之间的相似度，用于评价系统回复生成的质量。
- 查找准确率（Entity Match Rate，EMR）：对话系统提供了正确的实体（符合用户要求的餐厅）的对话所占比例，用于评价系统把握用户任务目标的能力。
- 问询回应 F1 得分（Request F1，ReqF1）：系统回应用户需求的 F1 得分，用于评价系统对用户需求的回应能力。
- 对话状态跟踪准确率（Joint Goal Accuracy，JG）：生成正确对话状态的对话轮数占总对话轮数的比例，用于评价系统的对话状态跟踪能力。

4.5.2　有监督实验结果与分析

在有监督实验中，我们使用 Camrest676 训练集中的所有对话数据及全部标注对进行模型训练。实现 DSNet（DSNet-A）时，所有编码器使用层数为 1、隐层神经元数量为 50 的双向 GRU 模型，所有解码器使用隐层神经元数量为 50 的标准 GRU 模型。词表大小设置为 850，输入词向量的维度为 50，dropout 概率为 0.35。我们使用 Adam 优化器[85] 进行模型训练，初始学习速率为 0.003，若连续 2 个训练周期损失不下降，则学习速率减半，连续 4 个训练周期损失不下降，则停止训练。

我们和 6 种基准模型进行了对比，包括 Camrest676 数据集上取得最佳实验结果的 4 种端到端模型 TSCP[33]（Sequicity 的模型实现）、SEDST[100]、FSDM[34] 和 MOSS[35]，以及 2 种对话状态跟踪模型 StateNet_PSI[54] 和 SIM[55]。前者用于比较生成系统回复的质量，后者用于比较模型的对话状态跟踪准确率。

模型		BLEU		Entity Match		Request F1		Joint Goal	
		avg	1-best	avg	1-best	avg	1-best	avg	1-best
E2E	TSCP[33]	-	0.237	-	0.927	-	0.854	-	-
	SEDST[100]	-	0.244	-	0.955	-	-	-	-
	FSDM[34]	-	0.258	-	0.935	-	0.862	-	-
	MOSS[35]	-	**0.259**	-	0.951	-	0.860	-	-
DST	StateNet_PSI[54]	-	-	-	-	-	-	0.889	-
	SIM[55]	-	-	-	-	-	-	0.895	-
E2E	DSNet	0.230	0.257	0.965	**0.973**	0.823	0.858	0.897	**0.942**
	DSNet-A	**0.232**	0.258	**0.968**	**0.973**	**0.844**	**0.873**	**0.902**	0.897

表 4.1　使用全部有标注数据训练的模型性能对比

使用全部有标注数据进行模型训练的实验结果见表4.1。由于 Camrest676 数据规模不大，模型训练的随机性较高，我们取不同的随机种子进行 10 次实验，报告各个评价指标的平均结果（avg 列）。鉴于一些其他研究中汇报的是单模型的最佳结果，为了保证可比，我们也选取了 10 次实验中 BLEU 得分最高的模型，作为最佳结果与其他工作进行比较（1-best 列）。从表4.1可以看到，我们的 DSNet 及 DSNet-A 模型所生成的系统回复语句，在对话任务相关的指标（EMR，ReqF1）上大幅度超越了现有模型，且在对话状态跟踪任务中的性能超越了专门为 DST 设计的模型，说明了我们提出的新框架及新模型结构的优越性。在引入系统对话动作的建模后，DSNet-A 比 DSNet 的性能又有所提升，尤其是对用户的回应方面（ReqF1 从 0.823 提升到 0.844），因为对话系统动作的标注数据为模型带来了更多的监督信息。

4.5.3　半监督实验结果与分析

在半监督实验中，我们将数据按比例分为有标注数据和无标注数据，进行了 50% 标注和 25% 标注两组实验：

- 在 50% 标注的实验中，对比模型在仅使用 50% 有标注数据进行有监督训练，和使用 50% 有标注数据加另外 50% 无标注数据进行半监督训练后的实验结果变化。
- 在 25% 标注的实验中，对比模型在仅使用 25% 有标注数据进行有监督训练，和使用 25% 有标注数据加另外 75% 无标注数据进行半监督训练后的实验结果变化。

DSNet 在半监督训练时，我们首先使用所有的有标注数据对模型进行有监督的预训练，以使模型尽可能多地学习到对话状态及系统对话动作的结构化信息。之后，我们使用全部数据（有监督 + 无监督）对模型进行半监督训练，分别使用各自的损失函数对模型进行优化。DSNet 模型具体实现和训练基本参数和有监督实验相同。在 SCVAE 中，我们将 KL 散度项的权重设为 0.5，在 SCRWS 中，我们使用粒子数 $N = 10$。

我们用 SEDST[100] 作为半监督实验的基线模型。SEDST 是一个基于 Sequicity 框架的端到端对话模型，也建模了推断模型 $q_\phi(\boldsymbol{B}_t|\boldsymbol{B}_{t-1}, \boldsymbol{C}_t, \boldsymbol{R}_t)$。但由于 Sequicity 框架下的模型无法应用推断算法，其使用了一种经验性的后验正则做法，将 $q_\phi(\boldsymbol{B}_t|\boldsymbol{B}_{t-1}, \boldsymbol{C}_t, \boldsymbol{R}_t)$ 和先验分布 $p(\boldsymbol{B}_t|\boldsymbol{B}_{t-1}, \boldsymbol{C}_t)$ 的 KL 散度作为正则项加在了有监督学习的最大似然损失函数上。这种做法在半监督实验中取得了一定的性能提升，但缺乏基本机器学习的理论保证，且实验过程存在不严谨。但作为对端到端对话模型

进行对话状态半监督学习的唯一现有工作，我们仍然将其作为基线方法，与 DSNet 进行比较。

模型	标注%	无标注%	BLEU	Entity Match	Request F1	Joint Goal
SEDST	50	0	0.192	0.852	-	-
SEDST	50	50	0.215	0.877	-	-
DSNet	50	0	0.215	0.938	0.771	0.846
DSNet (SCVAE)	50	50	0.223	0.950	0.795	0.882
DSNet (SCRWS)	50	50	**0.228**	0.962	0.802	**0.895**
DSNet-A	50	0	0.216	0.954	0.775	0.871
DSNet-A (SCVAE)	50	50	0.223	0.964	**0.805**	0.887
DSNet-A (SCRWS)	50	50	0.223	**0.965**	0.796	0.881

表 4.2　50% 有标注数据的半监督实验结果

模型	标注%	无标注%	BLEU	Entity Match	Request F1	Joint Goal
SEDST	25	0	0.192	0.852	-	-
SEDST	25	75	0.215	0.877	-	-
DSNet	25	0	0.212	0.891	0.749	0.734
DSNet (SCVAE)	25	75	**0.225**	0.931	0.790	0.776
DSNet (SCRWS)	25	75	0.222	**0.935**	**0.792**	0.770
DSNet-A	25	0	0.211	0.903	0.744	0.769
DSNet-A (SCVAE)	25	75	**0.225**	**0.935**	0.783	**0.780**
DSNet-A (SCRWS)	25	75	0.224	0.927	0.783	0.763

表 4.3　25% 有标注数据的半监督实验结果

50% 和 25% 有标注数据的半监督实验结果见表4.2和4.3。在这两个表格中，我们只报告了更具有说服力的 10 次实验的平均结果。从结果可以看出，在两种实验设定下，加入无标签数据进行半监督学习后，DSNet 和 DSNet-A 的各项指标都得到了一致性的显著提高。其中，在查找准确率（EMR）和对话状态跟踪准确率（JG）这两个取决于模型对话状态跟踪能力的指标上，无监督学习使得 50% 有标注实验中 EMR 从 0.938 最高提升到 0.965，JG 从 0.846 最高提升到 0.895，25% 有标注实验中 EMR 从 0.891 最高提升到 0.935，JG 从 0.734 最高提升到 0.780，无标注数据对系统学习对话状态跟踪的帮助极为明显。值得一提的是，在 50% 有标注数据的实验中，DSNet+SCRWS 取得的 EMR 和 JG 已经几乎达到了使用全部标注数据训练的水平，表明我们可以在不损失性能的情况下减少 50% 的对话状态标注数据。

在 SCVAE 和 SCRWS 两种无监督学习算法的对比中，我们发现 SCVAE 更适合于训练 DSNet-A，而 SCRWS 更适合训练 DSNet，综合来看在 50% 有标注数据的实验中，DSNet+SCRWS 取得了最好的结果；在 25% 有标注数据的实验中，DSNet-A+SCVAE 的组合取得了最好的结果。在实际应用时，我们可以根据不同的标注数据比例，进行模型和算法的灵活搭配，以得到最佳性能。在 DSNet 和现有方法 SEDST 的对比中，无论是不使用无标注数据的基线结果，还是加入了无标注数据后的半监督实验结果，DSNet 都显著好于 SEDST，以实验结果再次验证了 DSNet 相比于 SEDST 的原理性优势。

第 5 章　结论与展望

5.1　论文贡献总结

在本论文中，我们对现有端到端任务型对话系统中存在的两个问题：（1）缺少对多领域复杂对话任务的支持和（2）模型训练依赖大量有标注数据，进行了深入分析，并提出了改进方案。

在第三章中，我们提出了领域自适应的多级解码器网络模型 DAMD，可完成多领域复杂场景下的端到端对话建模任务。我们在现有最具挑战的多领域任务型对话数据集 MultiWOZ 上证明了 DAMD 模型的有效性，并强调了 DAMD 模型与其他多领域对话模型相比的优势所在。此外，我们使用 DAMD 模型研究了多领域对话中的“一对多”问题（同一语境下可存在多种不同的合理系统回复），提出了一种多动作数据增强方法 MADA，并展示了如何使用 DAMD 模型结合 MADA 学习到多元化的对话策略。

在第四章中，我们从现有 Sequicity 框架下对话模型的概率建模出发，指出现有框架无法进行无监督学习的局限性，提出了一种新的基于状态空间的对话模型框架，避免了现有框架的问题。在新框架下，我们提出了离散状态端到端对话模型 DSNet，并给出了 DSNet 训练的无监督学习算法，展示了如何使用有标注数据和无标注数据对模型半监督训练。我们通过任务型对话经典数据集 Camrest676 上的实验展示了 DSNet 相比于现有模型的优越性，以及半监督学习对端到端对话模型训练带来的显著性能提升。

5.2　未来研究方向

在本论文研究的基础上，我们未来可以考虑在以下方向进行进一步的研究与探索：

基于状态空间模型进行对话建模。在本研究中，我们给出了任务型对话系统的两种状态空间模型框架下的建模方式，并展示了其相比于其他框架的优势。作为一种灵活而成熟的序列数据建模框架，状态空间模型在对话建模中具有很大的应用潜力，进一步的研究工作可分为以下两方面：一方面，如何引入任务型对话系统中其他元素的建模，例如自然语言理解建模、端到端数据库搜索等；另一方面，如何在其他类型的对话任务，例如闲聊型对话、多轮问答中应用状态空间模型框架，都是未来值得探索的方向。

无监督学习算法优化。在本研究中，我们基于 VAE 和 RWS 两种无监督学习算法，提出了 SCVAE 和 SCRWS 用于解决对话模型的序列学习问题。在对话建模中应用其他更强大的无监督学习算法[101] 或针对序列数据的推断算法[102-104]，进一步提升无监督学习的性能，是一个值得探索的研究方向。

用户与系统的联合建模。在现有框架下，我们只为对话系统侧的变量进行了建模，而忽略了用户侧变量，例如用户语句、用户对话动作、用户目标的建模。鉴于对话中的用户建模和系统建模是对偶问题，如何应用本研究中提出的状态空间模型进行用户侧变量的建模，进而进行用户和系统的联合建模，是一个很有意思的研究问题。

插图索引

图 1.1 任务型对话示例：餐厅信息查询 2
图 1.2 任务型对话系统的两种系统框架 2
图 2.1 剑桥餐厅查询数据库示意图 7
图 2.2 对话状态跟踪示例 8
图 2.3 循环神经网络展开结构示意图 11
图 2.4 编解码器网络模型中的注意力机制（图引自[28]） 13
图 2.5 引入拷贝机制的序列到序列学习模型（图引自[79]） 14
图 2.6 Sequicity 多级编解码器框架示意图（图引自[33]） 16
图 2.7 基于多级编解码器的端到端对话模型结构对比 17
图 3.1 DAMD 模型结构及系统各中间状态示例 19
图 3.2 任务型对话数据集的统计信息对比（图引自[82]） 21
图 3.3 任务型对话中的“一对多”现象 25
图 3.4 同一对话状态可对应多种合理的系统对话动作 26
图 3.5 多动作数据增强方法原理 27
图 4.1 Sequicity 模型结构图 31
图 4.2 Sequicity 框架下对话系统的概率图模型 32
图 4.3 SSM 框架下对话模型的概率图模型 33
图 4.4 加入对话动作建模的概率图模型 34
图 4.5 DSNet 模型结构 36
图 4.6 DSNet-A 模型结构 37
图 4.7 DSNet 的对话状态解码工作原理 38
图 4.8 DSNet-A 的系统对话动作解码工作原理 39
图 4.9 DSNet 的推断模型示意 40

表格索引

表 3.1 MultiWOZ 上各对话模型的回复生成结果对比 23
表 3.2 DAMD 模型的错误生成实例展示 24
表 3.3 多对话动作解码结果 29
表 3.4 多回复生成的人工评测结果 30
表 4.1 使用全部有标注数据训练的模型性能对比 44
表 4.2 50% 有标注数据的半监督实验结果 46
表 4.3 25% 有标注数据的半监督实验结果 46

参考文献

[1] Sordoni A, Galley M, Auli M, et al. A neural network approach to context-sensitive generation of conversational responses // Proceedings of the 2015 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2015: 196-205.

[2] Li J, Monroe W, Ritter A, et al. Deep reinforcement learning for dialogue generation. arXiv preprint arXiv:1606.01541, 2016.

[3] Xu A, Liu Z, Guo Y, et al. A new chatbot for customer service on social media // Proceedings of the 2017 CHI Conference on Human Factors in Computing Systems. 2017: 3506-3510.

[4] Yu D, Cohn M, Yang Y M, et al. Gunrock: A social bot for complex and engaging long conversations // 2019 Conference on Empirical Methods in Natural Language Processing. 2019: 79-84.

[5] Zhou L, Gao J, Li D, et al. The design and implementation of xiaoice, an empathetic social chatbot. Computational Linguistics, 2020:53-93.

[6] Kiyota Y, Kurohashi S, Kido F. Dialog navigator: a question answering system based on large text knowledge base // COLING '02 Proceedings of the 19th international conference on Computational linguistics - Volume 1. 2002: 1-7.

[7] Mollá D, Vicedo J L. Question answering in restricted domains: An overview. Computational Linguistics, 2007, 33(1):41-61.

[8] tau Yih W, Chang M W, He X, et al. Semantic parsing via staged query graph generation: Question answering with knowledge base // Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers): volume 1. 2015: 1321-1331.

[9] Papineni K A, Roukos S, Ward R T. Natural language task-oriented dialog manager and method. 1998.

[10] Young S. Using pomdps for dialog management // 2006 IEEE Spoken Language Technology Workshop. 2006: 8-13.

[11] Wen T H, Vandyke D, Mrksic N, et al. A network-based end-to-end trainable task-oriented dialogue system. arXiv preprint arXiv:1604.04562, 2016.

[12] Zhou J, Chen P, Zhao(Y, et al. Building task-oriented dialogue systems for online shopping // AAAI. 2017: 4618-4626.

[13] Young S, Gasic M, Thomson B, et al. Pomdp-based statistical spoken dialog systems:. Proceedings of the IEEE, 2013, 101(5):1160-1179.

[14] LeCun Y, Bengio Y, Hinton G. Deep learning. Nature, 2015, 521(7553):436-444.

[15] Liu B, Lane I. Attention-based recurrent neural network models for joint intent detection and slot filling. // Interspeech 2016. 2016: 685-689.

[16] Jaech A, Heck L P, Ostendorf M. Domain adaptation of recurrent neural networks for natural language understanding. // Interspeech 2016. 2016: 690-694.

[17] Henderson M, Thomson B, Young S. Word-based dialog state tracking with recurrent neural networks // Proceedings of the 15th Annual Meeting of the Special Interest Group on Discourse and Dialogue (SIGDIAL). 2014: 292-299.

[18] Mrksic N, Séaghdha D □, Wen T H, et al. Neural belief tracker: Data-driven dialogue state tracking // Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers): volume 1. 2017: 1777-1788.

[19] Su P H, Gasic M, Mrksic N, et al. On-line active reward learning for policy optimisation in spoken dialogue systems. arXiv preprint arXiv:1605.07669, 2016.

[20] Peng B, Li X, Li L, et al. Composite task-completion dialogue policy learning via hierarchical deep reinforcement learning // Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. 2017: 2231-2240.

[21] Wen T H, Gasic M, Mrkšić N, et al. Semantically conditioned lstm-based natural language generation for spoken dialogue systems // Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. 2015: 1711-1721.

[22] Wen T H, Gasic M, Mrksic N, et al. Multi-domain neural network language generation for spoken dialogue systems // Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2016: 120-129.

[23] Liu B, Lane I. An end-to-end trainable neural network model with belief tracking for task-oriented dialog. // Interspeech 2017. 2017: 2506-2510.

[24] Li X, Chen Y N, Li L, et al. End-to-end task-completion neural dialogue systems // Proceedings of the Eighth International Joint Conference on Natural Language Processing (Volume 1: Long Papers): volume 1. 2017: 733-743.

[25] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks // Advances in Neural Information Processing Systems 27. 2014: 3104-3112.

[26] Cho K, van Merrienboer B, Gulcehre C, et al. Learning phrase representations using rnn encoder–decoder for statistical machine translation // Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2014: 1724-1734.

[27] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate // ICLR 2015 : International Conference on Learning Representations 2015. 2015.

[28] Luong M T, Pham H, Manning C D. Effective approaches to attention-based neural machine translation // Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. 2015: 1412-1421.

[29] Vinyals O, Le Q V. A neural conversational model. arXiv preprint arXiv:1506.05869, 2015.

[30] Serban I V, Sordoni A, Bengio Y, et al. Building end-to-end dialogue systems using generative hierarchical neural network models // AAAI'16 Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence. 2016: 3776-3783.

[31] Eric M, Manning C D. A copy-augmented sequence-to-sequence architecture gives good performance on task-oriented dialogue. // Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 2, Short Papers. 2017: 468-473.

[32] Zhao T, Lu A, Lee K, et al. Generative encoder-decoder models for task-oriented spoken dialog systems with chatting capability // Proceedings of the 18th Annual SIGdial Meeting on Discourse and Dialogue. 2017: 27-36.

[33] Lei W, Jin X, Kan M Y, et al. Sequicity: Simplifying task-oriented dialogue systems with single sequence-to-sequence architectures // ACL 2018: 56th Annual Meeting of the Association for Computational Linguistics: volume 1. 2018: 1437-1447.

[34] Shu L, Molino P, Namazifar M, et al. Flexibly-structured model for task-oriented dialogues // Proceedings of the 20th Annual SIGdial Meeting on Discourse and Dialogue. 2019.

[35] Liang W, Tian Y, Cheng C, et al. Moss: End-to-end dialog system framework with modular supervision // AAAI 2020 : The Thirty-Fourth AAAI Conference on Artificial Intelligence. 2020.

[36] Kingma D P, Welling M. Auto-encoding variational bayes // ICLR 2014 : International Conference on Learning Representations (ICLR) 2014. 2014.

[37] Sohn K, Yan X, Lee H. Learning structured output representation using deep conditional generative models // NIPS'15 Proceedings of the 28th International Conference on Neural Information Processing Systems - Volume 2. 2015: 3483-3491.

[38] Bornschein J, Bengio Y. Reweighted wake-sleep // ICLR 2015 : International Conference on Learning Representations 2015. 2015.

[39] Gu S, Ghahramani Z, Turner R E. Neural adaptive sequential monte carlo // NIPS'15 Proceedings of the 28th International Conference on Neural Information Processing Systems - Volume 2. 2015: 2629-2637.

[40] Nguyen N, Guo Y. Comparisons of sequence labeling algorithms and extensions // Proceedings of the 24th international conference on Machine learning. 2007: 681-688.

[41] Raymond C, Riccardi G. Generative and discriminative algorithms for spoken language understanding // INTERSPEECH. 2007: 1605-1608.

[42] Yao K, Zweig G, Hwang M Y, et al. Recurrent neural networks for language understanding. // INTERSPEECH. 2013: 2524-2528.

[43] Yao K, Peng B, Zhang Y, et al. Spoken language understanding using long short-term memory neural networks // 2014 IEEE Spoken Language Technology Workshop (SLT). 2014: 189-194.

[44] Xu P, Sarikaya R. Contextual domain classification in spoken language understanding systems using recurrent neural network // ICASSP 2014 - 2014 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2014: 136-140.

[45] Liu B, Lane I. Joint online spoken language understanding and language modeling with recurrent neural networks. // Proceedings of the 17th Annual Meeting of the Special Interest Group on Discourse and Dialogue. 2016: 22-30.

[46] Dai Y, Ou Z, Ren D, et al. Tracking of enriched dialog states for flexible conversational information access // 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2018: 6139-6143.

[47] Haffner P, Tur G, Wright J. Optimizing svms for complex call classification // 2003 IEEE International Conference on Acoustics, Speech, and Signal Processing, 2003. Proceedings. (ICASSP '03).: volume 1. 2003: 632-635.

[48] Sarikaya R, Hinton G E, Ramabhadran B. Deep belief nets for natural language call-routing // 2011 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2011: 5680-5683.

[49] Tur G, Deng L, Hakkani-Tur D, et al. Towards deeper understanding: Deep convex networks for semantic utterance classification // 2012 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2012: 5045-5048.

[50] Williams J D, Raux A, Henderson M. The dialog state tracking challenge series: A review. Dialogue & Discourse, 2016, 7(3):4-33.

[51] Henderson M, Thomson B, Young S. Robust dialog state tracking using delexicalised recurrent neural networks and unsupervised adaptation // 2014 IEEE Spoken Language Technology Workshop (SLT). 2014: 360-365.

[52] Mrkšić N, Séaghdha D □, Thomson B, et al. Multi-domain dialog state tracking using recurrent neural networks // Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 2: Short Papers): volume 2. 2015: 794-799.

[53] Zhong V, Xiong C, Socher R. Global-locally self-attentive dialogue state tracker. arXiv preprint arXiv:1805.09655, 2018.

[54] Ren L, Xie K, Chen L, et al. Towards universal dialogue state tracking // EMNLP 2018: 2018 Conference on Empirical Methods in Natural Language Processing. 2018: 2780-2786.

[55] Zhu C, Zeng M, Huang X. Sim: A slot-independent neural model for dialogue state tracking // Proceedings of the 20th Annual SIGdial Meeting on Discourse and Dialogue. 2019.

[56] Xu P, Hu Q. An end-to-end approach for handling unknown slot values in dialogue state tracking // ACL 2018: 56th Annual Meeting of the Association for Computational Linguistics: volume 1. 2018: 1448-1457.

[57] Wu C S, Madotto A, Hosseini-Asl E, et al. Transferable multi-domain state generator for task-oriented dialogue systems // ACL 2019 : The 57th Annual Meeting of the Association for Computational Linguistics. 2019: 808-819.

[58] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805, 2018.

[59] Lee H, Lee J, Kim T Y. Sumbt: Slot-utterance matching for universal and scalable belief tracking // ACL 2019 : The 57th Annual Meeting of the Association for Computational Linguistics. 2019: 5478-5483.

[60] Chao G L, Lane I. Bert-dst: Scalable end-to-end dialogue state tracking with bidirectional encoder representations from transformer // Interspeech 2019. 2019.

[61] Kim S, Yang S, Kim G, et al. Efficient dialogue state tracking by selectively overwriting memory. arXiv preprint arXiv:1911.03906, 2019.

[62] Zhang J G, Hashimoto K, Wu C S, et al. Find or classify? dual strategy for slot-value predictions on multi-domain dialog state tracking. arXiv preprint arXiv:1910.03544, 2019.

[63] Bohus D, Rudnicky A I. The ravenclaw dialog management framework: Architecture and systems. Computer Speech & Language, 2009, 23(3):332-361.

[64] Wen T H, Miao Y, Blunsom P, et al. Latent intention dialogue models // ICML'17 Proceedings of the 34th International Conference on Machine Learning - Volume 70. 2017: 3732-3741.

[65] Zhang Z, Huang M, Zhao Z, et al. Memory-augmented dialogue management for task-oriented dialogue systems. ACM Transactions on Information Systems, 2019, 37(3):34.

[66] Shu L, Xu H, Liu B, et al. Modeling multi-action policy for task-oriented dialogues // 2019 Conference on Empirical Methods in Natural Language Processing. 2019: 1304-1310.

[67] Liu B, Tür G, Hakkani-Tür D, et al. End-to-end optimization of task-oriented dialogue model with deep reinforcement learning. arXiv preprint arXiv:1711.10712, 2017.

[68] Zhang Z, Li X, Gao J, et al. Budgeted policy learning for task-oriented dialogue systems // ACL 2019 : The 57th Annual Meeting of the Association for Computational Linguistics. 2019: 3742-3751.

[69] Reiter E, Dale R. Building natural language generation systems. 2000.

[70] Eric M, Krishnan L, Charette F, et al. Key-value retrieval networks for task-oriented dialogue. // Proceedings of the 18th Annual SIGdial Meeting on Discourse and Dialogue. 2017: 37-49.

[71] Madotto A, Wu C S, Fung P. Mem2seq: Effectively incorporating knowledge bases into end-to-end task-oriented dialog systems // ACL 2018: 56th Annual Meeting of the Association for Computational Linguistics: volume 1. 2018: 1468-1478.

[72] Balakrishnan A, Rao J, Upasani K, et al. Constrained decoding for neural nlg from compositional representations in task-oriented dialogue. arXiv preprint arXiv:1906.07220, 2019.

[73] Mikolov T, Karafiát M, Burget L, et al. Recurrent neural network based language model // INTERSPEECH. 2010: 1045-1048.

[74] Kalchbrenner N, Blunsom P. Recurrent continuous translation models // Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing. 2013: 1700-1709.

[75] Graves A, rahman Mohamed A, Hinton G. Speech recognition with deep recurrent neural networks // 2013 IEEE International Conference on Acoustics, Speech and Signal Processing. 2013: 6645-6649.

[76] Schuster M, Paliwal K. Bidirectional recurrent neural networks. IEEE Transactions on Signal Processing, 1997, 45(11):2673-2681.

[77] Bengio Y, Simard P, Frasconi P. Learning long-term dependencies with gradient descent is difficult. IEEE Transactions on Neural Networks, 1994, 5(2):157-166.

[78] Hochreiter S, Schmidhuber J. Long short-term memory. Neural Computation, 1997, 9(8):1735-1780.

[79] Gu J, Lu Z, Li H, et al. Incorporating copying mechanism in sequence-to-sequence learning // Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers): volume 1. 2016: 1631-1640.

[80] Zhou G, Luo P, Xiao Y, et al. Elastic responding machine for dialog generation with dynamically mechanism selecting // AAAI-18 AAAI Conference on Artificial Intelligence. 2018: 5730-5737.

[81] Rajendran J, Ganhotra J, Singh S, et al. Learning end-to-end goal-oriented dialog with multiple answers // EMNLP 2018: 2018 Conference on Empirical Methods in Natural Language Processing. 2018: 3834-3843.

[82] Budzianowski P, Wen T H, Tseng B H, et al. Multiwoz - a large-scale multi-domain wizard-of-oz dataset for task-oriented dialogue modelling // EMNLP 2018: 2018 Conference on Empirical Methods in Natural Language Processing. 2018: 5016-5026.

[83] Chen W, Chen J, Qin P, et al. Semantically conditioned dialog response generation via hierarchical disentangled self-attention // ACL 2019 : The 57th Annual Meeting of the Association for Computational Linguistics. 2019: 3696-3709.

[84] Mehri S, Srinivasan T, Eskenazi M. Structured fusion networks for dialog // Proceedings of the 20th Annual SIGdial Meeting on Discourse and Dialogue. 2019.

[85] Kingma D P, Ba J L. Adam: A method for stochastic optimization // ICLR 2015 : International Conference on Learning Representations 2015. 2015.

[86] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need // Proceedings of the 31st International Conference on Neural Information Processing Systems. 2017: 5998-6008.

[87] Zhao T, Zhao R, Eskenazi M. Learning discourse-level diversity for neural dialog models using conditional variational autoencoders // Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers): volume 1. 2017: 654-664.

[88] Zhou G, Luo P, Cao R, et al. Mechanism-aware neural machine for dialogue response generation. // AAAI. 2017: 3400-3407.

[89] Li J, Monroe W, Jurafsky D. A simple, fast diverse decoding algorithm for neural generation. arXiv preprint arXiv:1611.08562, 2016.

[90] Fan A, Lewis M, Dauphin Y. Hierarchical neural story generation // ACL 2018: 56th Annual Meeting of the Association for Computational Linguistics: volume 1. 2018: 889-898.

[91] Holtzman A, Buys J, Forbes M, et al. The curious case of neural text degeneration. arXiv preprint arXiv:1904.09751, 2019.

[92] Jennrich R I, Schluchter M D. Unbalanced repeated-measures models with structured covariance matrices. Biometrics, 1986, 42(4):805-820.

[93] Kalman R E. A new approach to linear filtering and prediction problems. Journal of Basic Engineering, 1960, 82(1):35-45.

[94] Rabiner L. A tutorial on hidden markov models and selected applications in speech recognition. Proceedings of the IEEE, 1989, 77(2):267-296.

[95] Gu S, Levine S, Sutskever I, et al. Muprop: Unbiased backpropagation for stochastic neural networks // ICLR 2016 : International Conference on Learning Representations 2016. 2016.

[96] Mnih A, Rezende D J. Variational inference for monte carlo objectives // ICML'16 Proceedings of the 33rd International Conference on International Conference on Machine Learning - Volume 48. 2016: 2188-2196.

[97] Bengio Y, Léonard N, Courville A C. Estimating or propagating gradients through stochastic neurons for conditional computation. arXiv preprint arXiv:1308.3432, 2013.

[98] Jang E, Gu S, Poole B. Categorical reparameterization with gumbel-softmax // ICLR 2017 : International Conference on Learning Representations 2017. 2017.

[99] Liu J S, Chen R. Sequential monte carlo methods for dynamic systems. 1997.

[100] Jin X, Lei W, Ren Z, et al. Explicit state tracking with semi-supervisionfor neural dialogue generation // Proceedings of the 27th ACM International Conference on Information and Knowledge Management. 2018: 1403-1412.

[101] Xu H, Ou Z. Joint stochastic approximation learning of helmholtz machines. arXiv preprint arXiv:1603.06170, 2016.

[102] Andrieu C, Doucet A, Holenstein R. Particle markov chain monte carlo methods. Journal of The Royal Statistical Society Series B-statistical Methodology, 2010, 72(3):269-342.

[103] Naesseth C A, Linderman S, Ranganath R, et al. Variational sequential monte carlo // The 21st International Conference on Artificial Intelligence and Statistics, Playa Blanca, Lanzarote, Canary Islands, April 9-11, 2018: volume 84. 2018: 968-977.

[104] Le T A, Igl M, Rainforth T, et al. Auto-encoding sequential monte carlo // ICLR 2018 : International Conference on Learning Representations 2018. 2018.

致　谢

衷心感谢我的导师欧智坚老师对本人的精心指导。我从大三加入欧老师的实验室开始第一次接触科研，到研一第一次在国际会议发表论文，再到今天完成硕士项目的毕业要求并完成论文，科研路上的每一个成长阶段都离不开欧老师的引导与帮助。欧老师对我的言传身教，是将会伴随我一生的宝贵财富。

感谢俞舟老师在我去加州大学戴维斯分校进行暑研时对我的悉心指导。在短短三个月中，俞老师让我对自然语言理解和对话系统研究的认识产生了质的提升，并帮助我提高了论文的写作水平。非常感谢俞老师对我的帮助！

感谢我的父母一直以来对我的支持，他们永远是我最坚强的后盾。特别是疫情期间，在无法返校的情况下，我在家完成了毕业论文的全部撰写工作，这期间父母对我无微不至的照顾为我顺利完成论文提供了重要支持。谢谢！

感谢 SPMI 实验室全体同学们对我的帮助和支持。特别是和我做同一个方向的师兄戴音培，为我的科研和申请提供了非常多的帮助，和他讨论问题让我受益匪浅，特此致谢！

最后感谢我的朋友李佳钉、李彤、孟岳、唐紫健、张原、和我的室友王颖、张才荣在我硕士期间对我的帮助和支持，谢谢你们。也谢谢所有在清华陪我踢球的小伙伴们。

声　明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签　名：张亦弛　日　期：2020年5月15日

附录 A　SCRWS 中的 SMC 算法流程

Algorithm SMC

Input: model parameter θ, ϕ, particle number N, dialog data $(U_{1:T}, R_{1:T})$.
for $k = 1, 2, \cdots, N$ **do**　// In parallel
　Sample $B_1^k \sim p_\theta(B_1|U_1)$
　Compute importance weights $w_1^k = p_\theta(R_1|B_1^k, U_1))$
end for
Normalize $W_1^k = \frac{w_1^k}{\sum_{j=1}^N w_1^j}$, for $k = 1, 2, \cdots, N$
for $t = 2, \cdots, T$ **do**
　for $k = 1, 2, \cdots, N$ **do**　// In parallel
　　Sample $A_{t-1}^k \sim \mathcal{F}(A_{t-1}|\mathbf{W}_{t-1})$
　　Sample $B_t^k \sim q_\phi(B_t|B_{t-1}^{A_{t-1}^k}, R_{t-1}, U_t, R_t)$
　　Set $B_{1:t}^k = (B_{1:t-1}^{A_{t-1}^k}, B_t^k)$
　　$w_t^k = \frac{p_\theta(B_t^k|B_{t-1}^{A_{t-1}^k}, R_{t-1}, U_t) p_\theta(R_t|B_t^k, R_{t-1}, U_t))}{q_\phi(B_t^k|B_{t-1}^{A_{t-1}^k}, R_{t-1}, U_t, R_t)}$
　end for
　Normalize $W_t^k = \frac{w_t^k}{\sum_{j=1}^N w_t^j}$, for $k = 1, 2, \cdots, N$
end for
Marginal likelihood $\hat{p}(R_{1:T}|U_{1:T}) = \prod_{t=1}^T \frac{1}{N} \sum_{k=1}^N w_t^k$
Return: Trajectories $\{B_{1:T}^k\}_{k=1}^N$, weights $\{W_{1:T}^k\}_{k=1}^N$, $\hat{p}(R_{1:T}|U_{1:T})$

个人简历、在学期间发表的学术论文与研究成果

个人简历

1995 年 3 月 25 日出生于北京市海淀区。

2013 年 9 月考入清华大学电子工程系电子信息科学与技术专业，2017 年 7 月本科毕业并获得工学学士学位。

2017 年 9 月免试进入清华大学电子工程系信息与通信工程专业，攻读硕士学位至今。

发表的学术论文

[1] Zhang Y, Ou Z, Yu Z. Task-oriented dialog systems that consider multiple appropriate responses under the same context. // AAAI 2020 : The Thirty-Fourth AAAI Conference on Artificial Intelligence. 2020. (重要国际会议 CCF A 类)

[2] Zhang Y, Ou Z. Learning sparse structured ensembles with stochastic gradient mcmc sampling and network pruning. // MLSP 2018 : IEEE 28th International Workshop on Machine Learning for Signal Processing (MLSP) (pp. 1–6). 2018. (EI 收录, 检索号:20184806138877.)